TP558 - Tópicos avançados em Machine Learning:

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming

IEEE Transactions on Wireless Communications (2026)

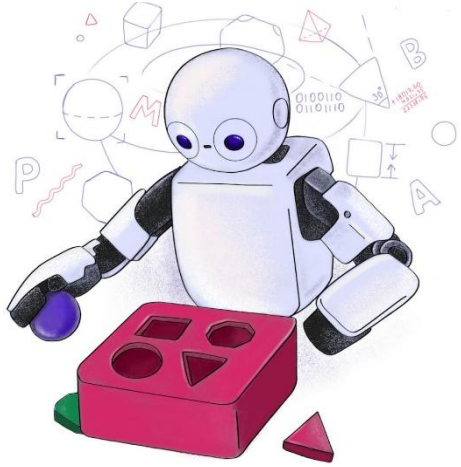

Inatel

Matheus Ferreira Silva
matheus.f@inatel.br

Contexto do Tema

- Surge conceito de **Fluid Antenna System (FAS)** para melhorar desempenho
- (2020) Kai Kit Wong

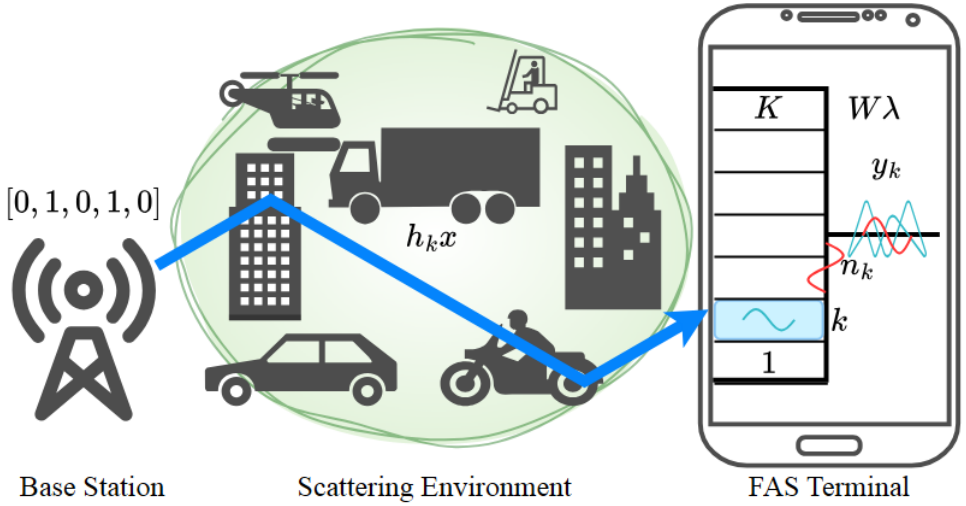

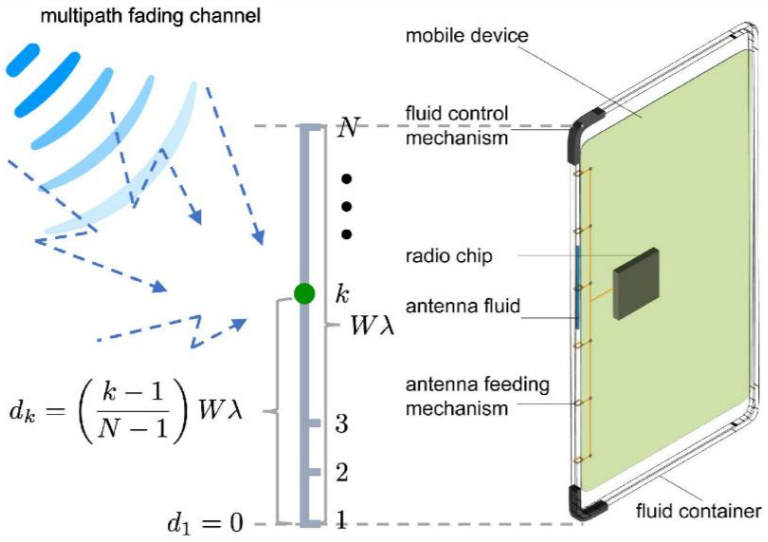

A relocalização da antena pode ser realizada movendo mecanicamente condutores líquidos por meio de um sistema microfluídico, ou ligando e desligando eletronicamente pixels radiantes.

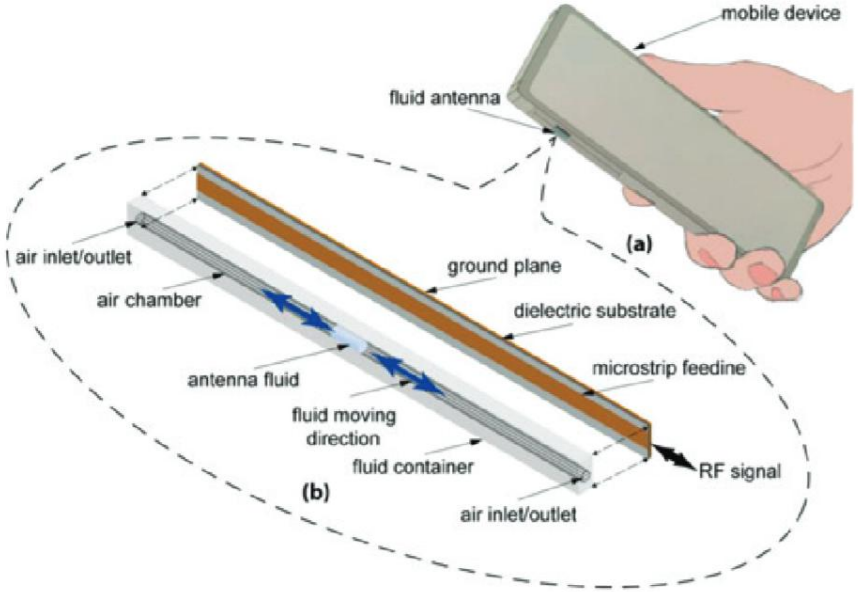

Low-Power AI-Based Port Selection for Fluid Antennas in Spatially Correlated Channels, WCNPS 2025.
Performance limits of fluid antenna systems, *IEEE Communications Letters*, Nov. 2020.
Fluid antenna system for 6G: When Bruce Lee inspires wireless communications, *Electronics Letters*, Nov. 2020.

Contexto do Tema

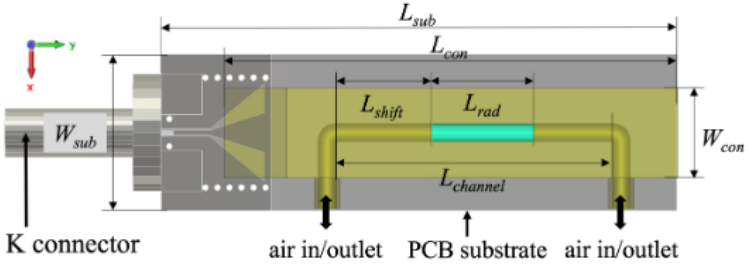

(a)

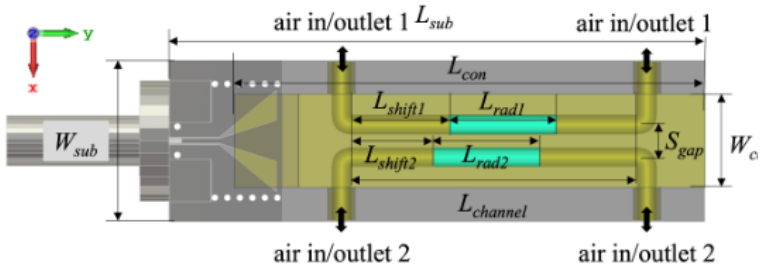

(b)

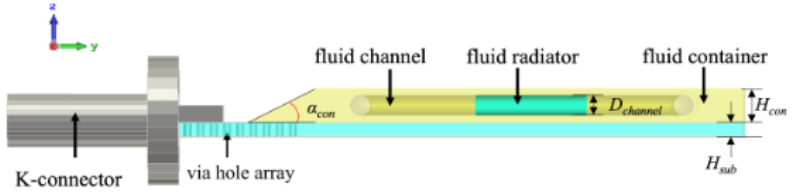

(c)

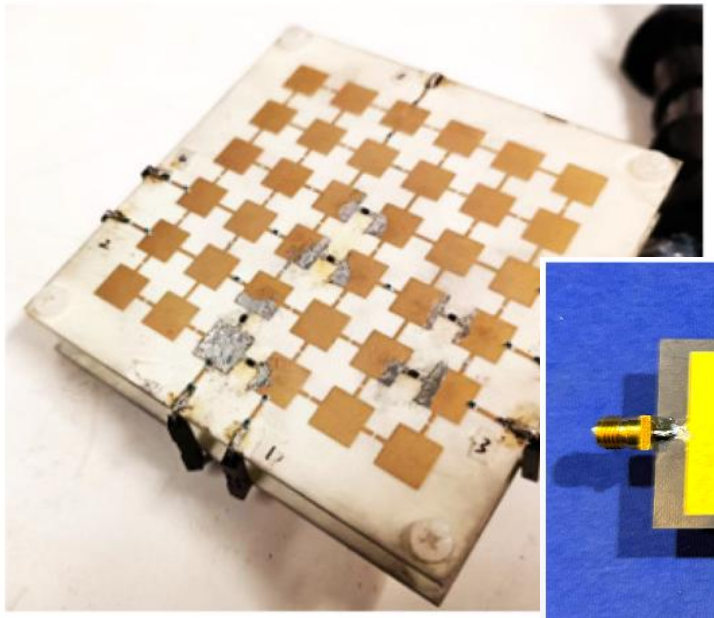

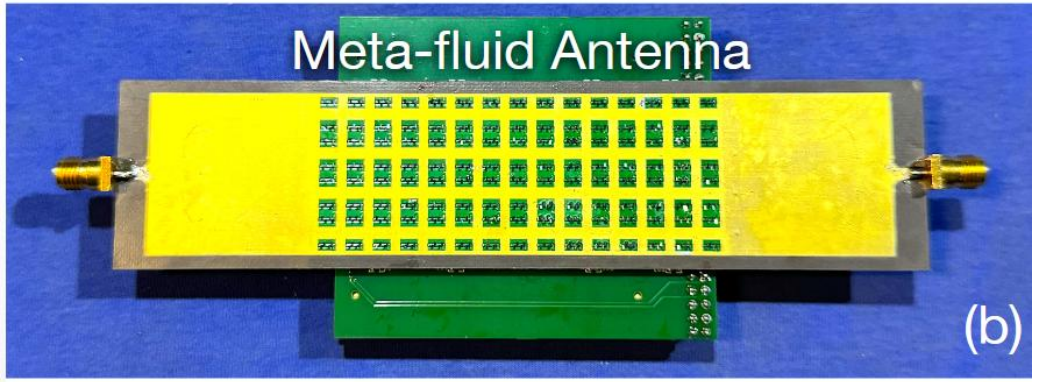

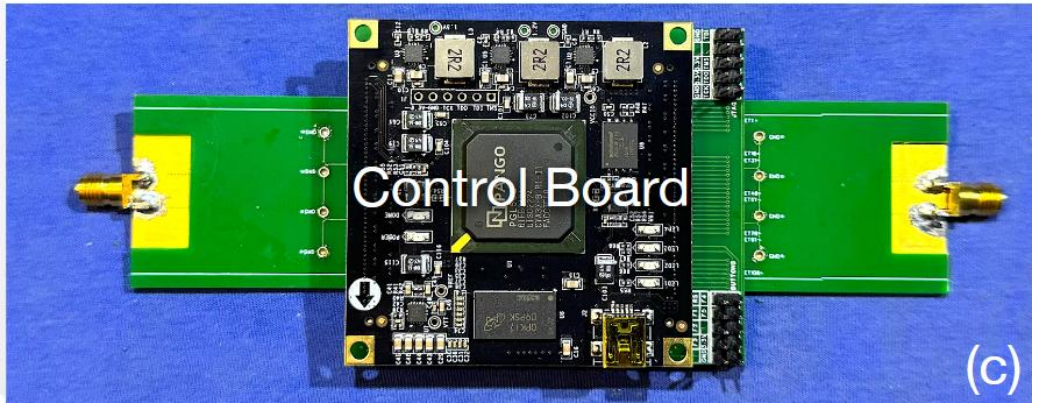

Design and implementation of mmWave surface wave enabled fluid antennas and experimental results for fluid antenna multiple access, arXiv:2405.09663, 2024.
A novel pixel-based reconfigurable antenna applied in fluid antenna systems with high switching speed, *IEEE Open Journal of Antennas and Propagation*, 2025.
Be water, my antennas: Riding on radio wave fluctuation in nature for spatial multiplexing using programmable meta-fluid antenna," arXiv:2502.04693, 2025.

Contexto do Tema

- Desafio fundamental: como otimizar beamforming e seleção de portas em FAS de forma eficiente e prática?
- Apesar de bons resultados em performance, muitos métodos têm alta complexidade, o que limita uso em tempo real. O autor ressalta necessidade de trade-off performance × latência.
- Grande ponto do autor: estudos algorítmicos frequentemente ignoram implementação em hardware, o que piora eficiência de execução (latência).

Introdução do artigo

- A literatura trata separadamente:
- beamforming/port selection em FAS
- GNN para beamforming
- FPGA para DL (aceleração genérica),
  mas falta a visão integrada de co-otimização hardware–software para tornar FAS realmente prática.

Introdução do artigo

- Proposta do método GNN-RPS, que integra Graph Neural Networks (GNN) com Random Port Selection (RPS) para otimização conjunta de beamforming e seleção de portas em Fluid Antenna Systems.
- Desenvolvimento de uma arquitetura multi-GNN, com treinamento centralizado utilizando informação global do canal e inferência distribuída executada localmente em cada estação base.
- Projeto de um acelerador de deep learning baseado em FPGA, com instruction set architecture (ISA) customizada e microarquitetura especializada, para reduzir a latência de inferência do algoritmo proposto.

Fundamentação teórica

- **Beamforming** é a técnica de ajustar os sinais transmitidos pelas antenas para direcionar energia para usuários específicos.
- WSR = soma (peso do usuário × taxa do usuário). O objetivo do artigo é **maximizar a WSR** sob restrição de potência.
- **Variáveis discretas** (port selection) + **variáveis contínuas** (beamforming) -> problema **misto-inteiro e não convexo**
- Instruction Set Architecture (ISA): define quais instruções o hardware executa e como operações são representadas

Fundamentação teórica

- **GNN** é uma rede neural projetada para dados representados como **grafos**.

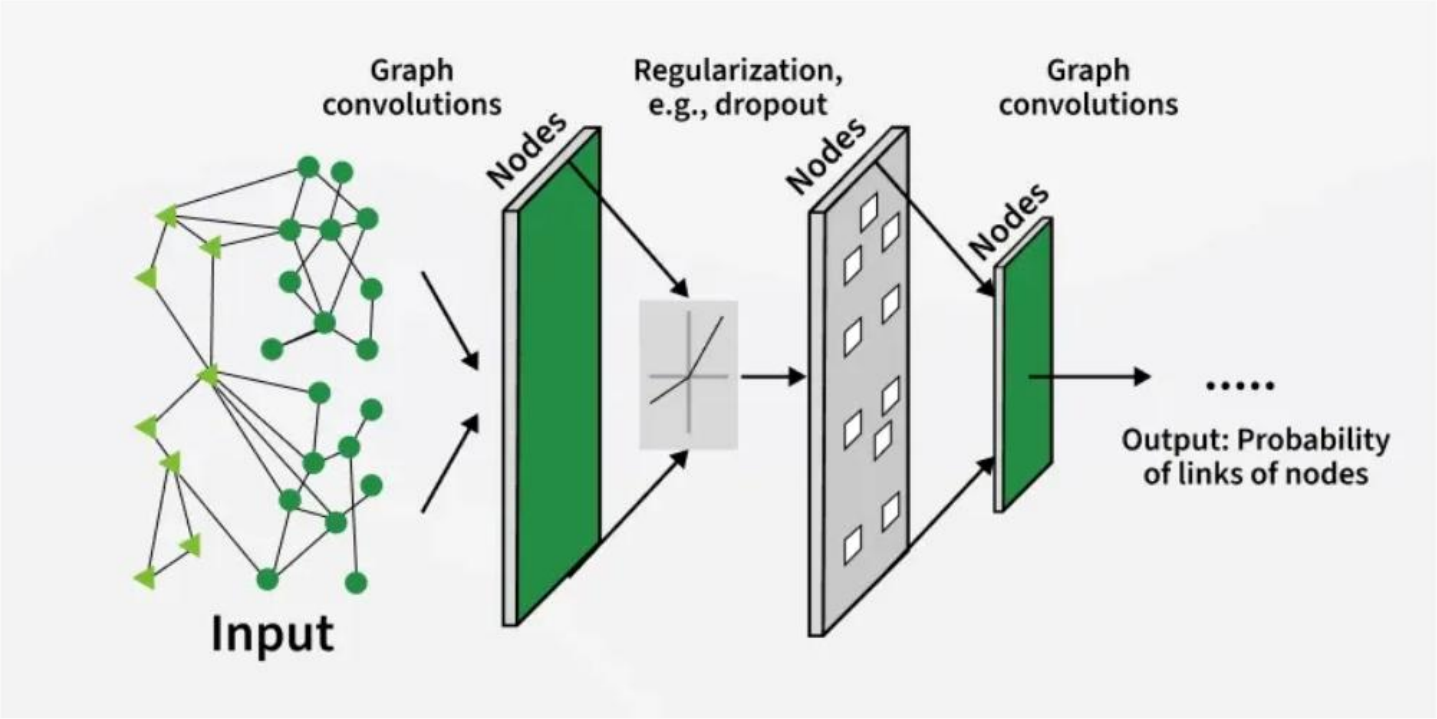

GEEKSFORGEEKS. What are Graph Neural Networks? [S. l.], 16 jan. 2024. Disponível em: https://www.geeksforgeeks.org/deep-learning/what-are-graph-neural-networks/. Acesso em: 6 mar. 2026.

Fundamentação teórica

- Random Port Selection (RPS) é uma estratégia simples para resolver a seleção de portas.

Procedimento:

1. escolher **aleatoriamente uma porta em cada FA**
2. executar a otimização de beamforming
3. calcular o desempenho obtido
4. repetir várias vezes
5. selecionar a melhor configuração

Fundamentação teórica

- **FPGA (Field Programmable Gate Array)** é um dispositivo de hardware reconfigurável. (Xilinx Virtex-7 XC7V690T FFG1761-3 FPGA)

Trabalhos relacionados

Beamforming e Port Selection em Fluid Antenna Systems

Ideia geral da literatura

- Trabalhos anteriores estudam otimização conjunta de beamforming e posicionamento/seleção de portas em sistemas FAS.
- Métodos típicos utilizam alternating optimization (AO) e técnicas de otimização convexa aproximada.
- Alguns trabalhos também exploram métodos de aprendizado (ex.: reinforcement learning).

Limitação identificada

- Esses métodos frequentemente apresentam alta complexidade computacional.
- A maioria dos trabalhos considera apenas o algoritmo, ignorando a eficiência de execução em hardware.

Trabalhos relacionados

Otimização de Beamforming baseada em GNN

Ideia geral da literatura

- Graph Neural Networks (GNNs) vêm sendo usadas para resolver problemas de otimização em redes sem fio.
- Aplicações incluem:
  - beamforming em MIMO multiusuário ou MISO
  - redes com RIS
  - sistemas satélite-terrestres

Limitação identificada

Apesar dos bons resultados, o uso de GNN para otimização conjunta de beamforming e port selection em FAS ainda é pouco explorado.

Trabalhos relacionados

Aceleração de Deep Learning em FPGA

Ideia geral da literatura

- FPGA é amplamente utilizado para acelerar inferência de redes neurais.
- Vantagens:
  - reconfigurabilidade
  - eficiência energética
  - baixa latência
  - adequado para aplicações em tempo real.

Limitação identificada

- A maioria dos aceleradores FPGA é genérica para DNN.
- Eles não exploram características específicas do algoritmo GNN usado para otimização de beamforming, o que reduz eficiência computacional.

Modelo de Sistema

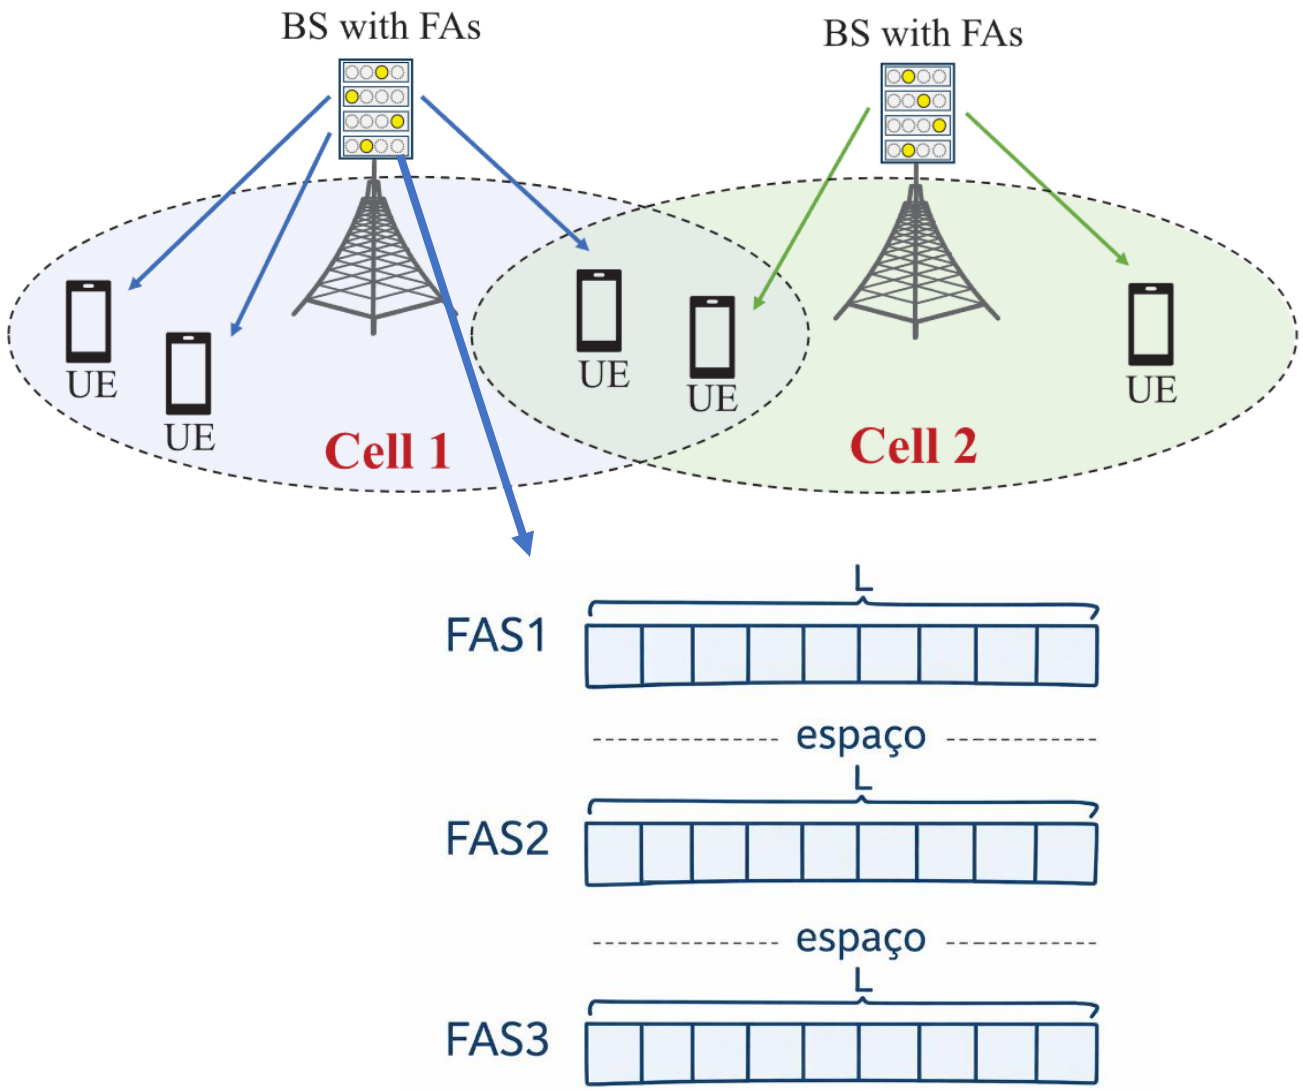

- Rede downlink multi-cell MIMO
- Cada Base Station (BS) atende múltiplos usuários simultaneamente
- Cada usuário possui antena fixa
- Cada BS possui N Fluid Antennas (FAs)
- Cada FA possui L portas selecionáveis
- A RF chain pode alternar entre as portas
- Portas distribuídas ao longo de Wλ
- Distância entre FAs ≥ λ/2

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Modelo de Canal

$$J_{(l,l')} = \delta^2 J_0\left(\frac{2\pi W\,|l-l'|}{L-1}\right), \tag{1}$$

onde $J_0(\cdot)$ é a função de Bessel de primeira espécie e ordem zero, e δ^2 denota a perda de percurso do canal. Através de decomposição espectral, a matriz de correlação espacial $\mathbf{J}$, cujo elemento (l,l') é denotado $\mathbf{J}_{(l,l')}$, pode ser representada por

$$\mathbf{J} = \mathbf{Q}\mathbf{A}\mathbf{Q}^H, \tag{2}$$

onde $\mathbf{Q} \in \mathbb{C}^{L\times L}$ contém os autovetores de $\mathbf{J} \in \mathbb{C}^{L\times L}$, e $\mathbf{\Lambda} \in \mathbb{C}^{L\times L}$ é uma matriz diagonal dos autovalores correspondentes. Com base nisso, o vetor de canal de todas as portas de uma FA até um UE pode ser escrrito como

$$\bar{\mathbf{h}} = \mathbf{Q}\mathbf{A}^{\frac{1}{2}}\mathbf{z}, \tag{3}$$

onde $\mathbf{z}$ é um vetor aleatório complexo Gaussiano independente e identicanente distribuído (i.i.d.), i.e., $z \sim \tilde{CN}(0, I_L)$.

- Ambiente com rich scattering
- Small-scale fading Rayleigh
- Portas da mesma FA possuem correlação espacial
- Correlação modelada pelo modelo de Jakes
- Canal resultante:

  Rayleigh correlacionado com desvanecimento
- CSI perfeito disponível nas BSs

Modelo de Transmissão de Sinal

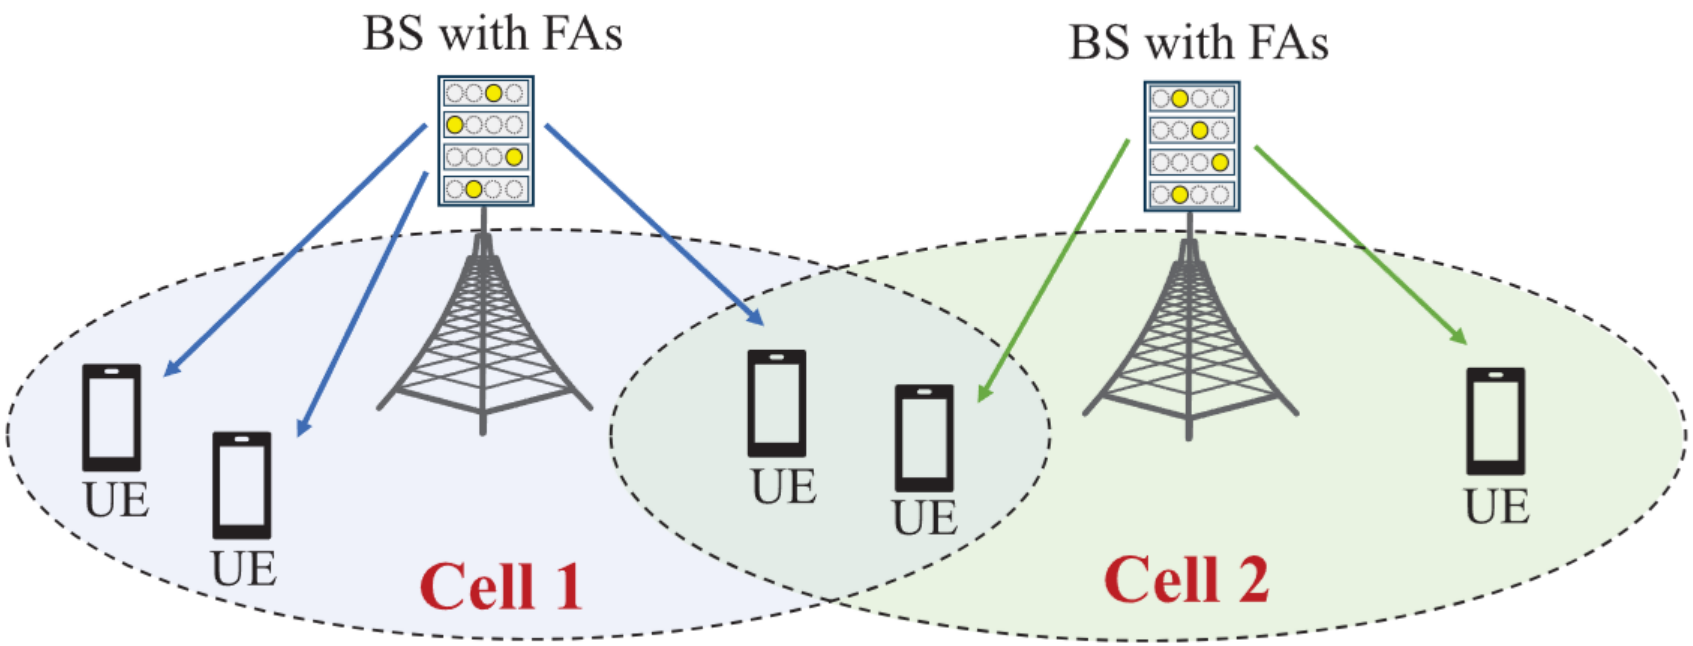

- O sinal recebido por cada usuário contém:
  - **Sinal desejado**
  - **Interferência intra-célula**
  - **Interferência inter-célula**
  - **Ruído térmico**

Ideia de Otimização Conjunta

Problema de otimização misto e não convexo

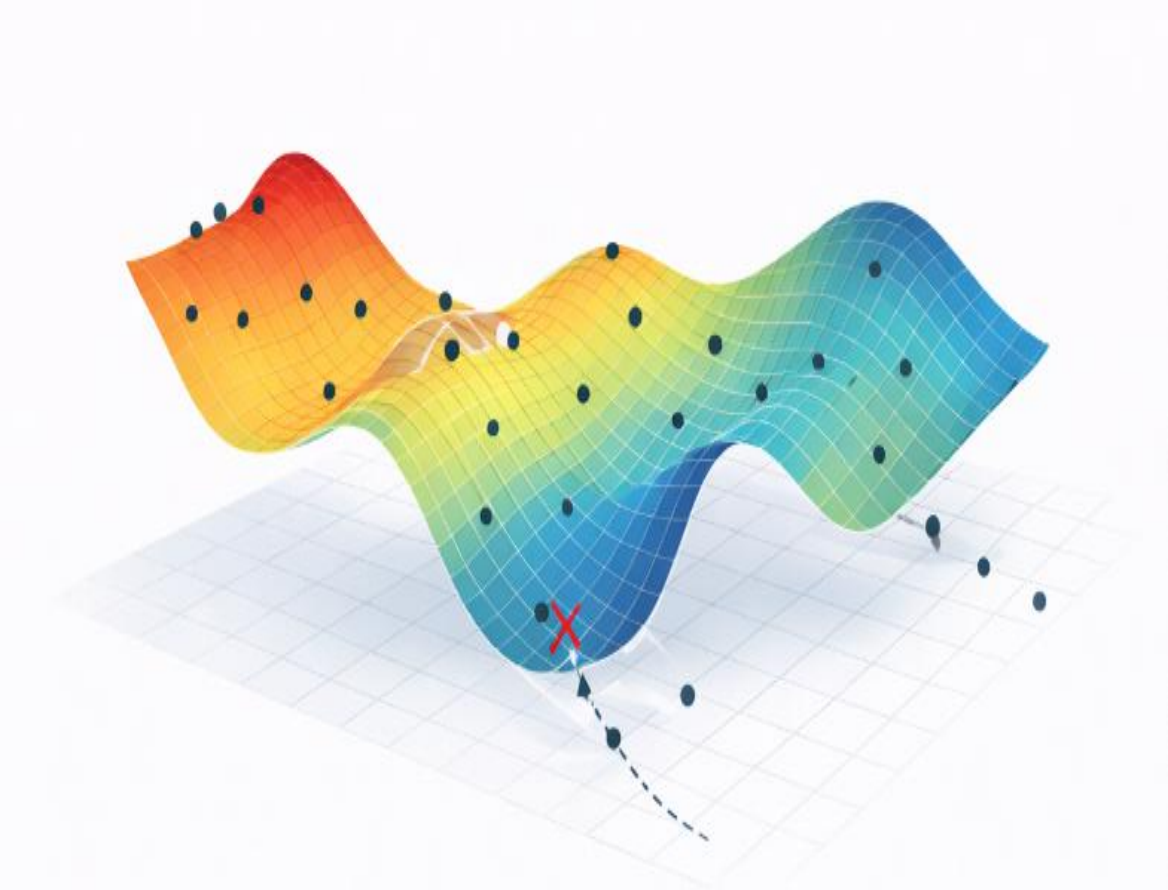

- Objetivo: **maximizar o desempenho da rede (WSR — Weighted Sum Rate)**
- Cada FA possui múltiplas portas candidatas
- Seleção adequada de portas permite:
  - melhorar o ganho do sinal desejado
  - reduzir interferência
  - melhorar o beamforming
- Port Selection e Beamforming devem ser otimizados juntos

Subproblema de Beamforming (Portas Fixas)

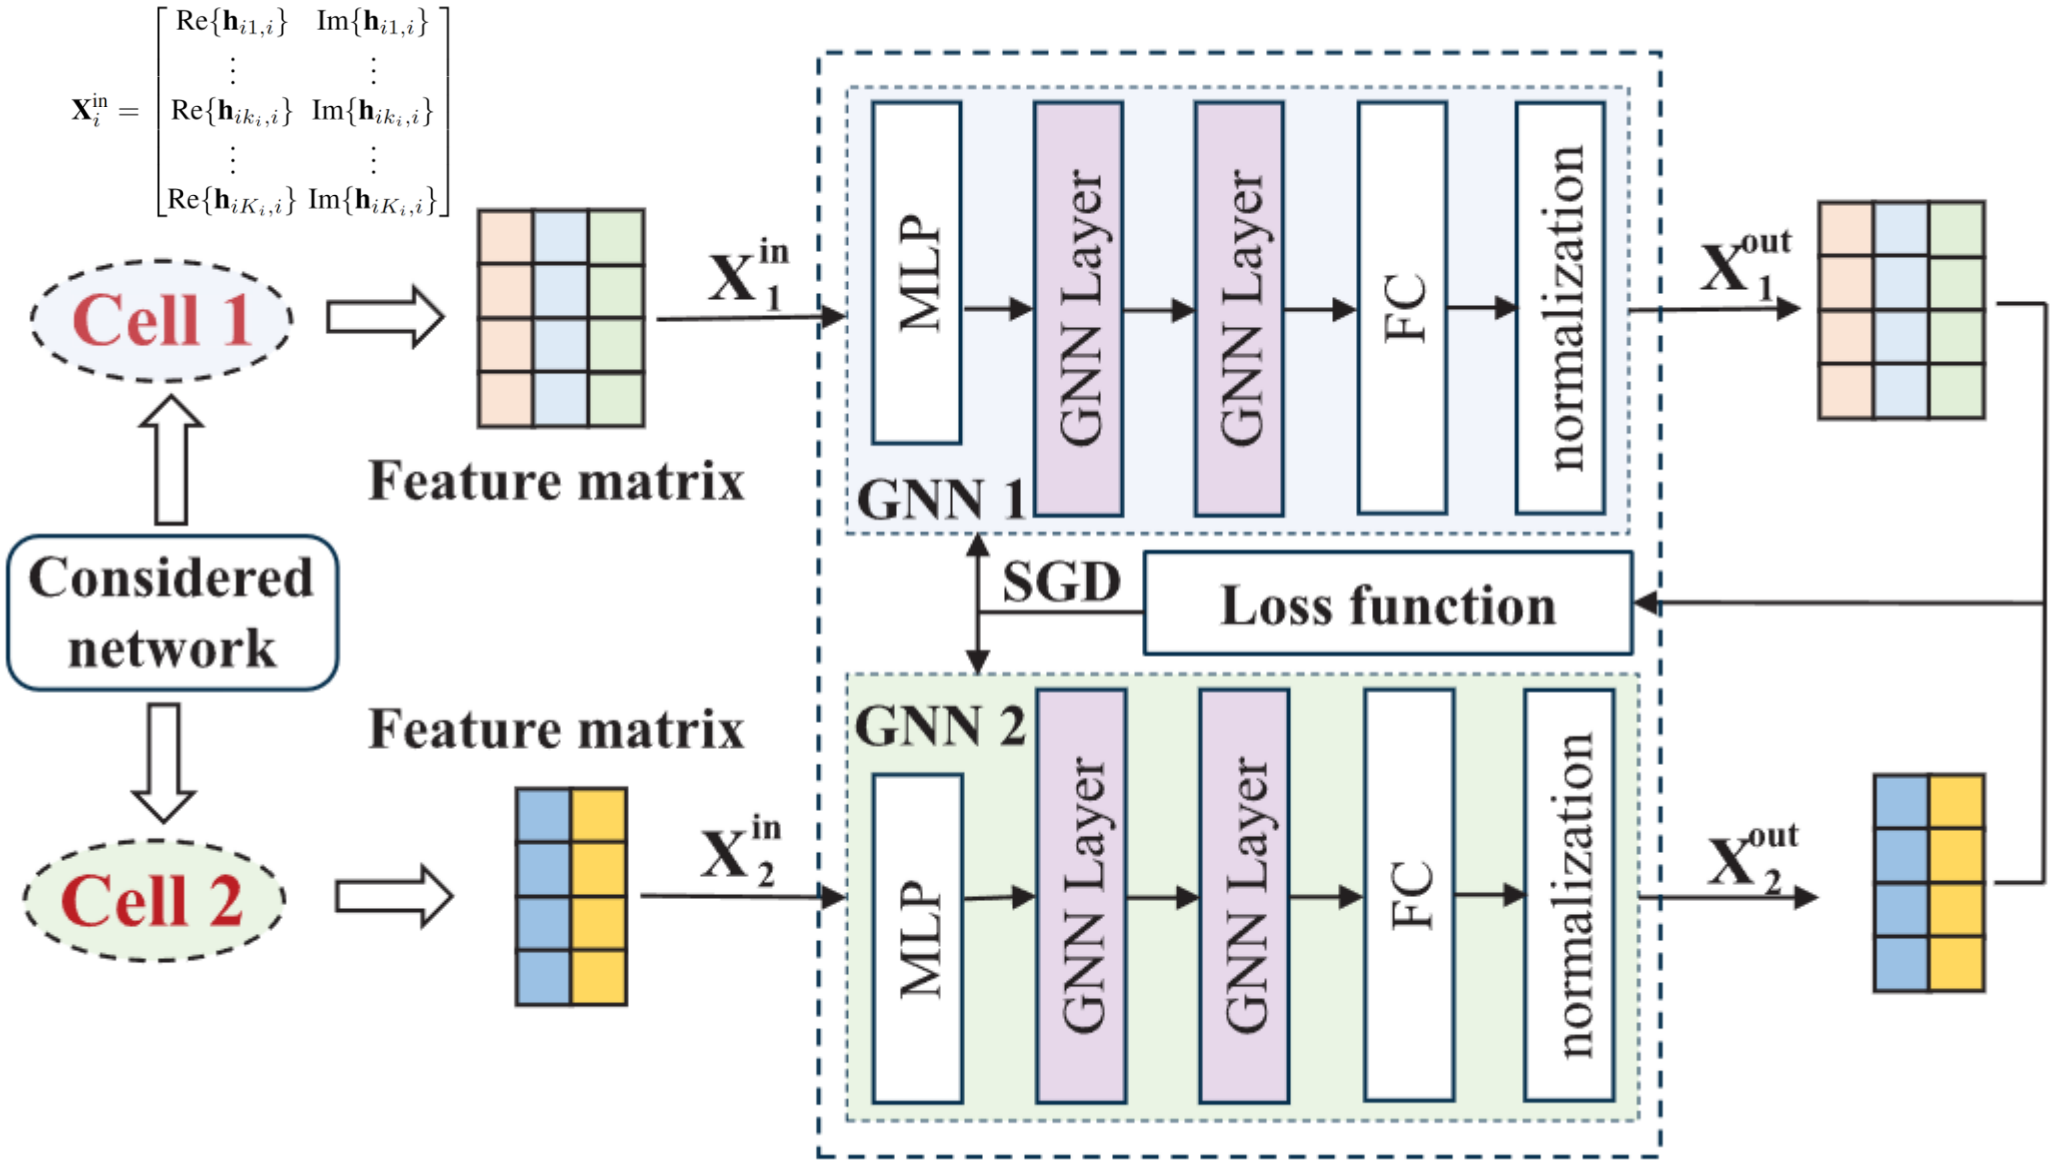

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Subproblema de Port Selection (RPS)

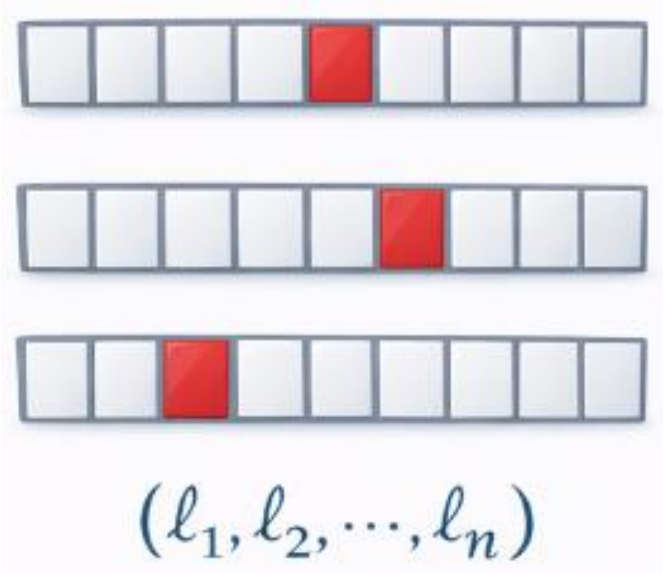

GNN

Compute Rate

Fluxo completo:

- Amostrar múltiplas configurações de portas
- Para cada configuração:
  - construir entrada da GNN
  - inferir beamforming
- Calcular taxa da rede
- Selecionar melhor solução

Apenas uma porta por FA pode ser ativada por vez

(porque existe uma única RF chain por FA que alterna entre as portas).

ISA e FPGA

Categorias de Instruções

1. Acesso à Memória

- Move dados entre DRAM e buffers internos
- Ex: carregar pesos da rede

2. Processamento de Matrizes

- Executa multiplicações matriciais
- Usado em camadas MLP / FC
- Implementado com Systolic Arrays

3. Pós-Processamento

- Operações da rede neural

Arquitetura do Hardware

- Unidade de Controle
- Unidades de Leitura/Escrita de Memória
- Unidade de Processamento de Matrizes
- Unidade de Pós-Processamento

ISA e FPGA

Execução Normal (CPU / GPU)

- Para cada configuração de portas:
- Port selection → GNN → cálculo da taxa

Problemas:

- Execução sequencial
- Pesos da rede recarregados várias vezes
- Alto tráfego de memória
- Latência ≈ N × T

Execução com FPGA (proposta)

- Avaliação simultânea de múltiplas configurações
- [$Input_1$, $Input_2$, $Input_3$] → GNN → resultados

Vantagens:

- Pesos carregados uma vez
- Reuso de computação
- Processamento paralelo
- Menos acesso à memória

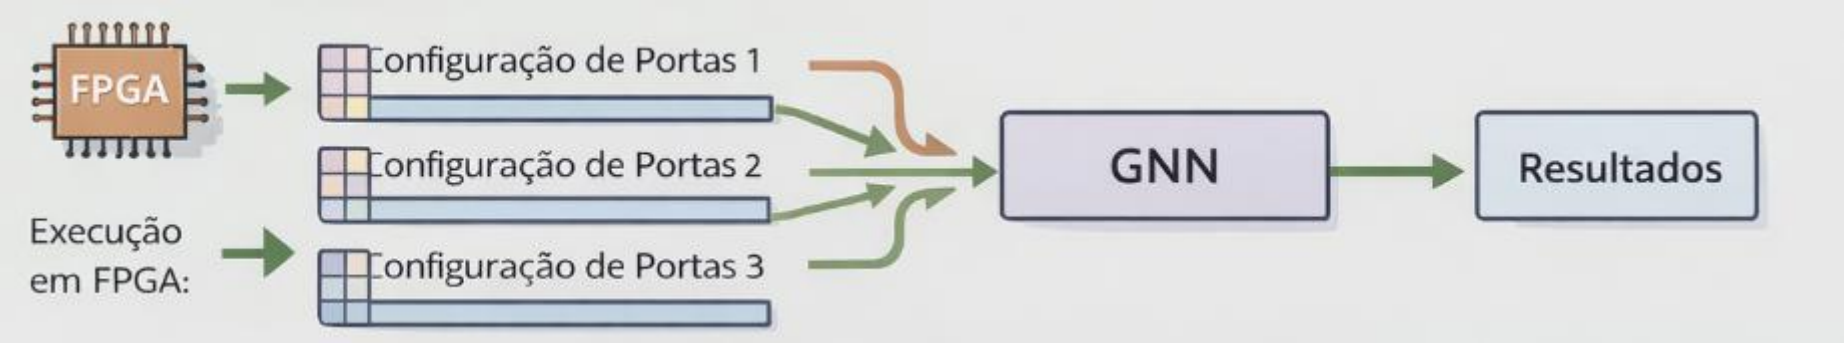

Resultados: Cenário Experimental e Configuração da GNN

Cenário de simulação

- Rede downlink multi-cell MIMO
- X células
- Y usuários por célula
- 1 BS por célula
- Cada BS com:
  - N fluid antennas
  - L portas por antena
- Apenas 1 porta ativa por FA
- Comprimento da FA: 0.5λ

Parâmetros de comunicação

- Distância dos usuários: 20 m a 30 m
- Potência por BS: 3 dBm
- Ruído: −90 dBm
- Pesos da WSR: $\omega = 1$

Configuração do treinamento

- Otimizador: Adam
- Learning rate inicial: 0.001
- Decaimento do learning rate: 0.995 a cada 100 passos
- 10.000 amostras para o treinamento
- Batch size: 200
- Conjunto de teste: 2.000 amostras

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados

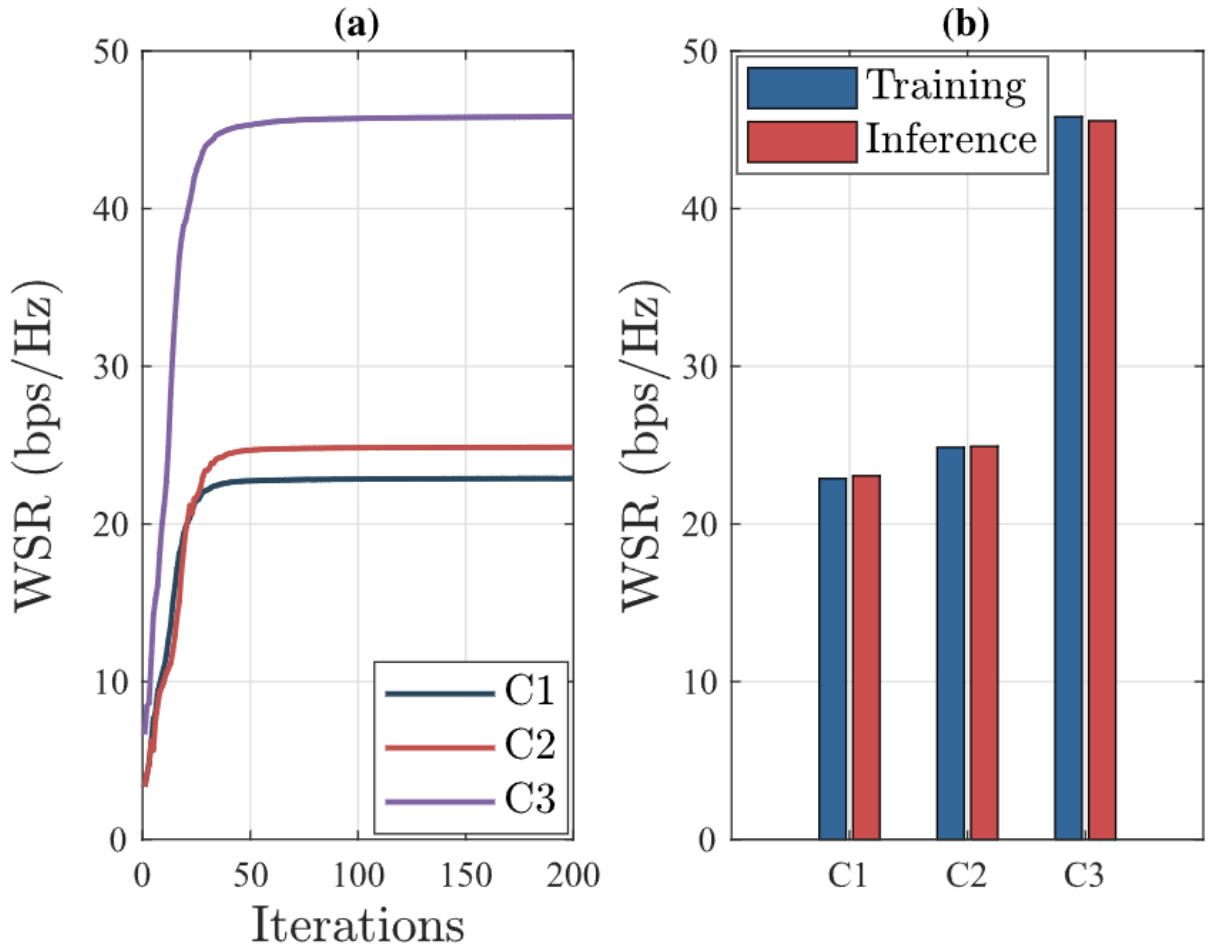

Fig. 5. Training and inference performance of the multi-GNN method under different parameter settings (I, K, P): $C_1 = (2, 2, 0)$, $C_2 = (2, 2, 3)$, and $C_3 = (4, 2, 0)$.

I: número de células / estações base (BSs) na rede

K: número de usuários por célula

P: potência de transmissão por BS, em dBm

Principal resultado

- A GNN converge em cerca de 30 iterações
- Resultados de treino e teste são muito próximos
- Indica boa generalização

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados

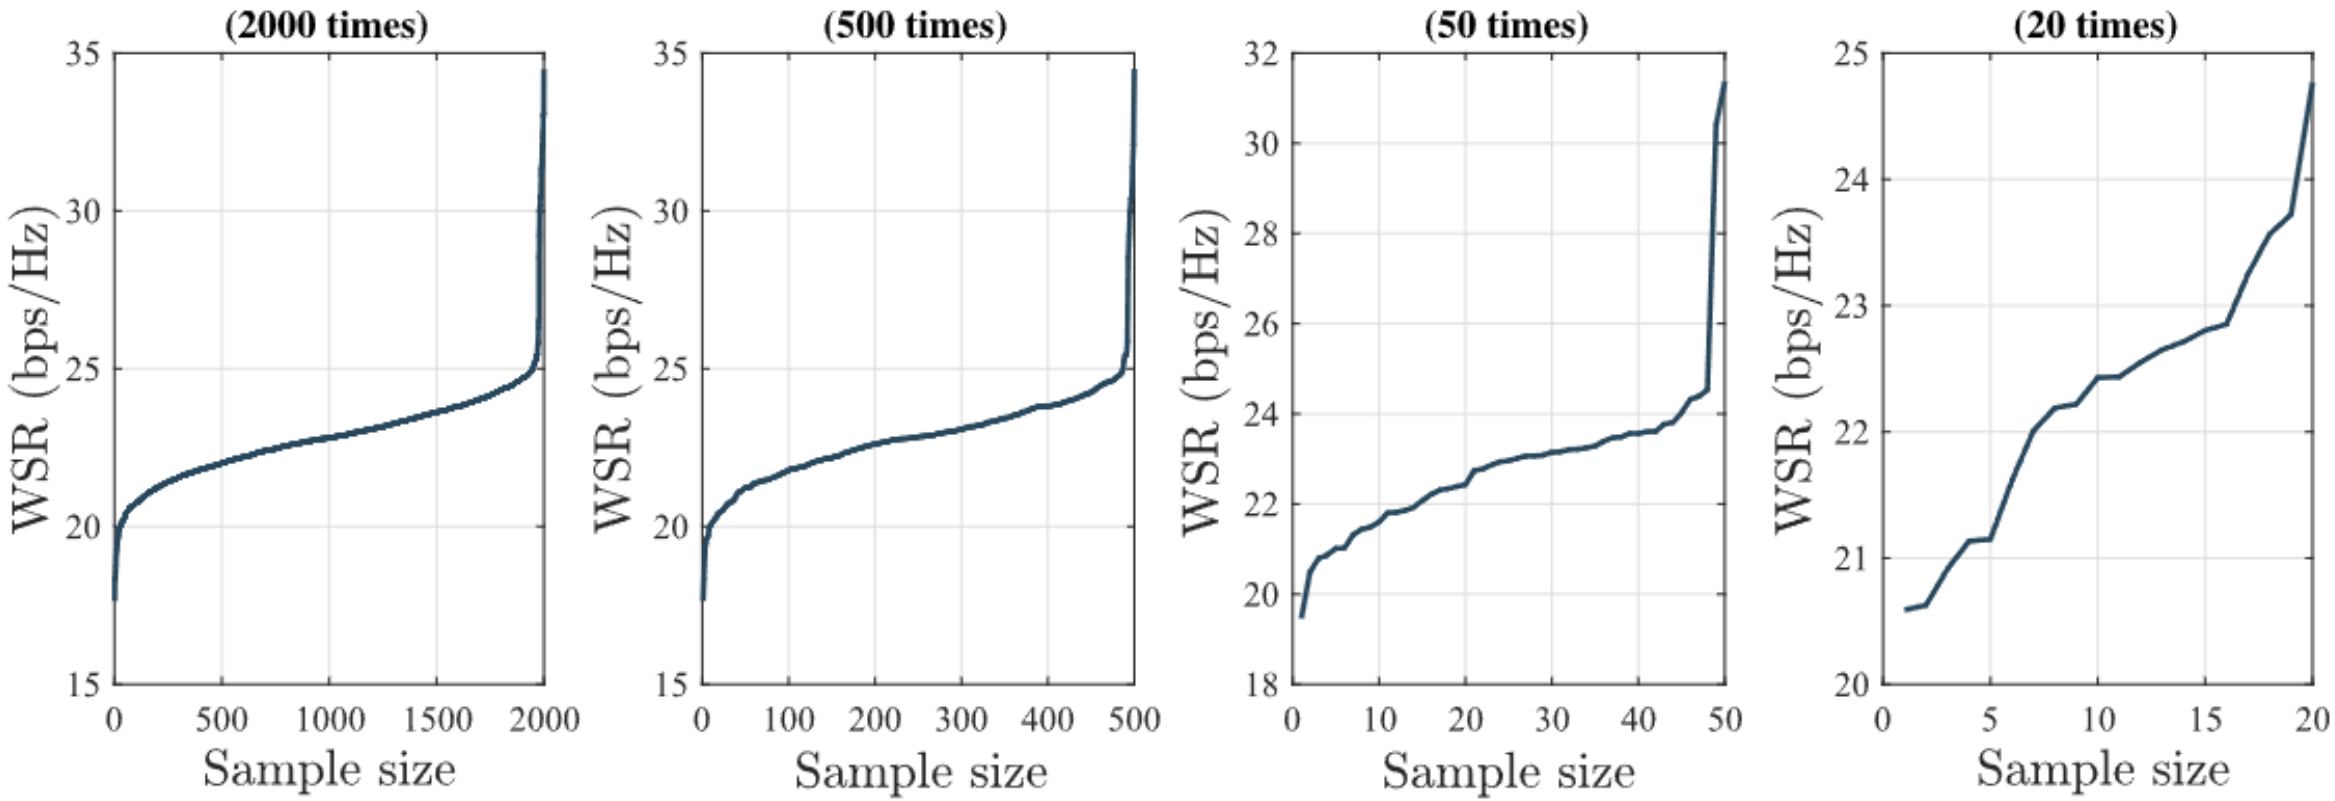

Fig. 6. WSR distribution with varying numbers of RPSs.

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados: Comparação com Estado da Arte

Métodos comparados

- GNN-RandomMax
- GNN-RandomSingle
- GNN-Exhaustive
- MMSE-Exhaustive
- ZF-Exhaustive
- MRT-Exhaustive

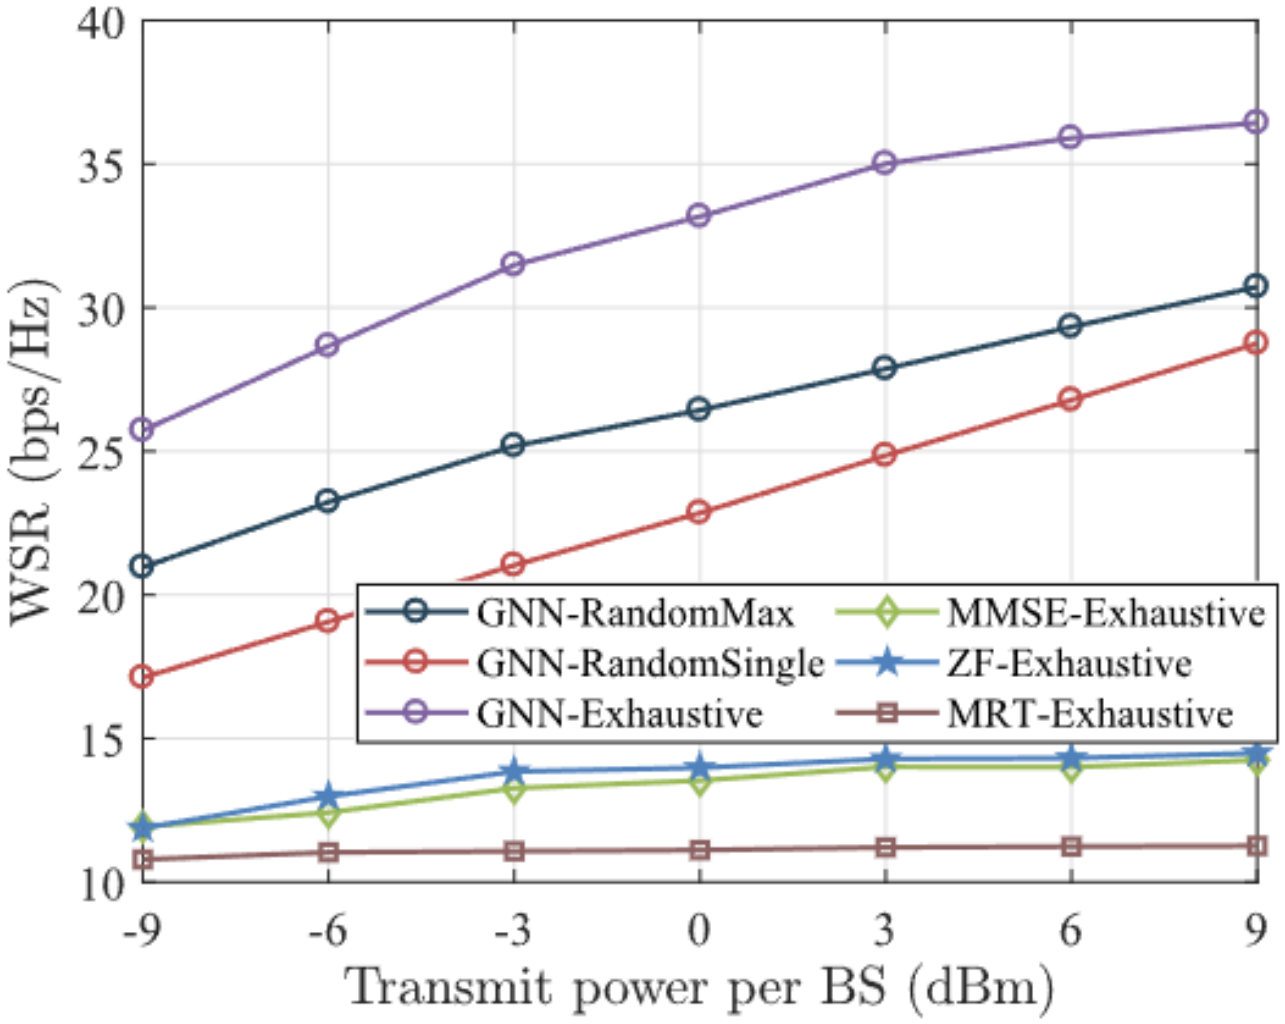

Fig. 7. The relationship between the WSR and the transmit power.

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados: Comparação com Estado da Arte

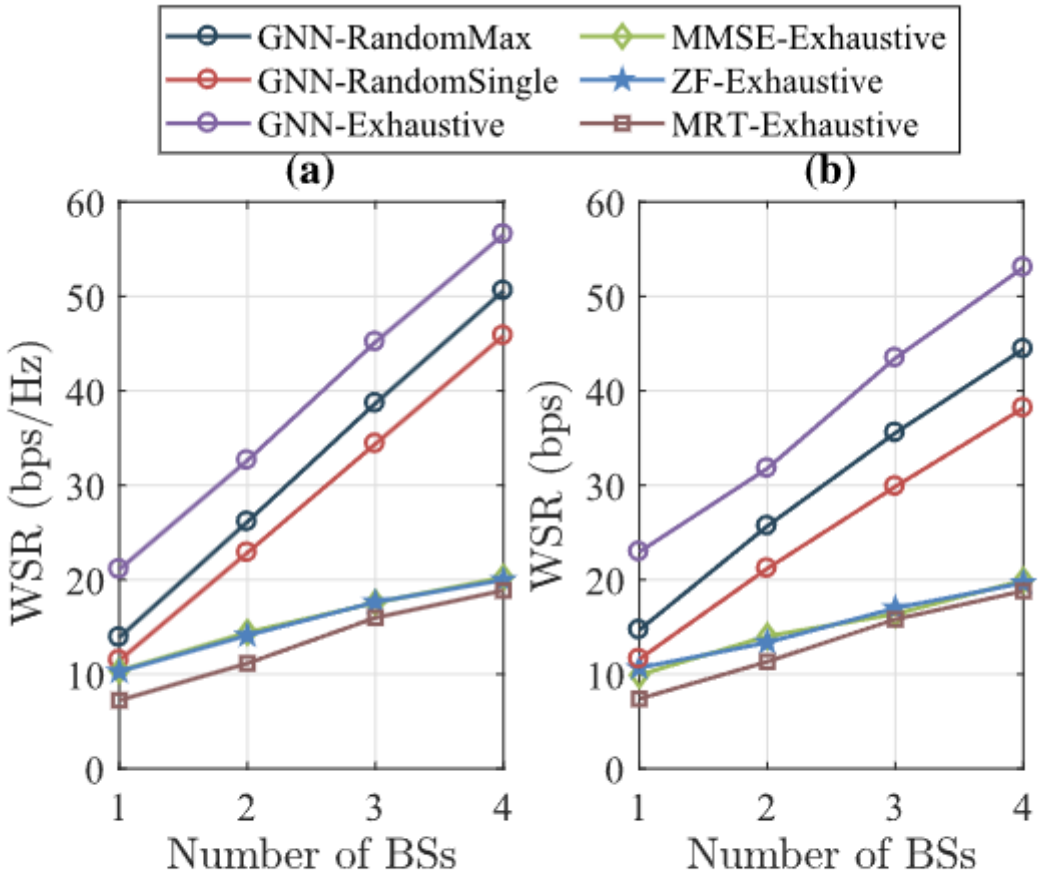

Fig. 8. The relationship between the WSR and the number of BSs under two cases: (a) constant transmit power per BS; (b) fixed total transmit power shared among all BSs.

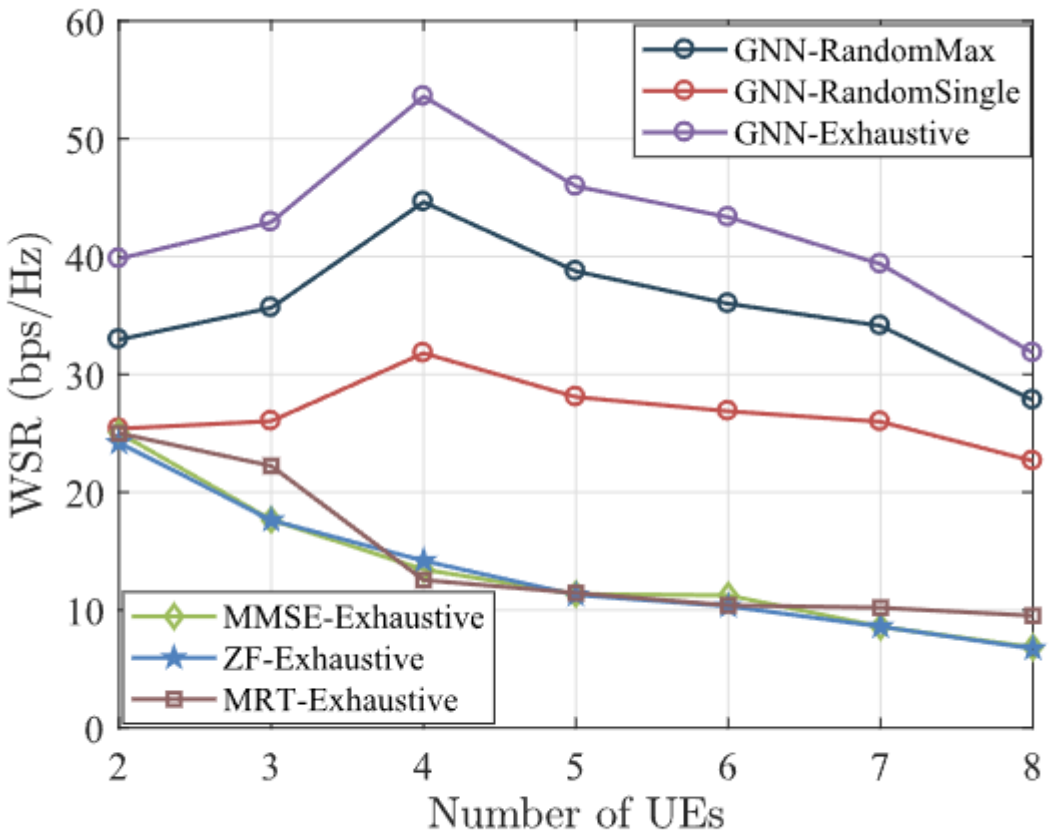

Fig. 9. The relationship between the WSR and the number of UEs.

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados: Comparação com Estado da Arte

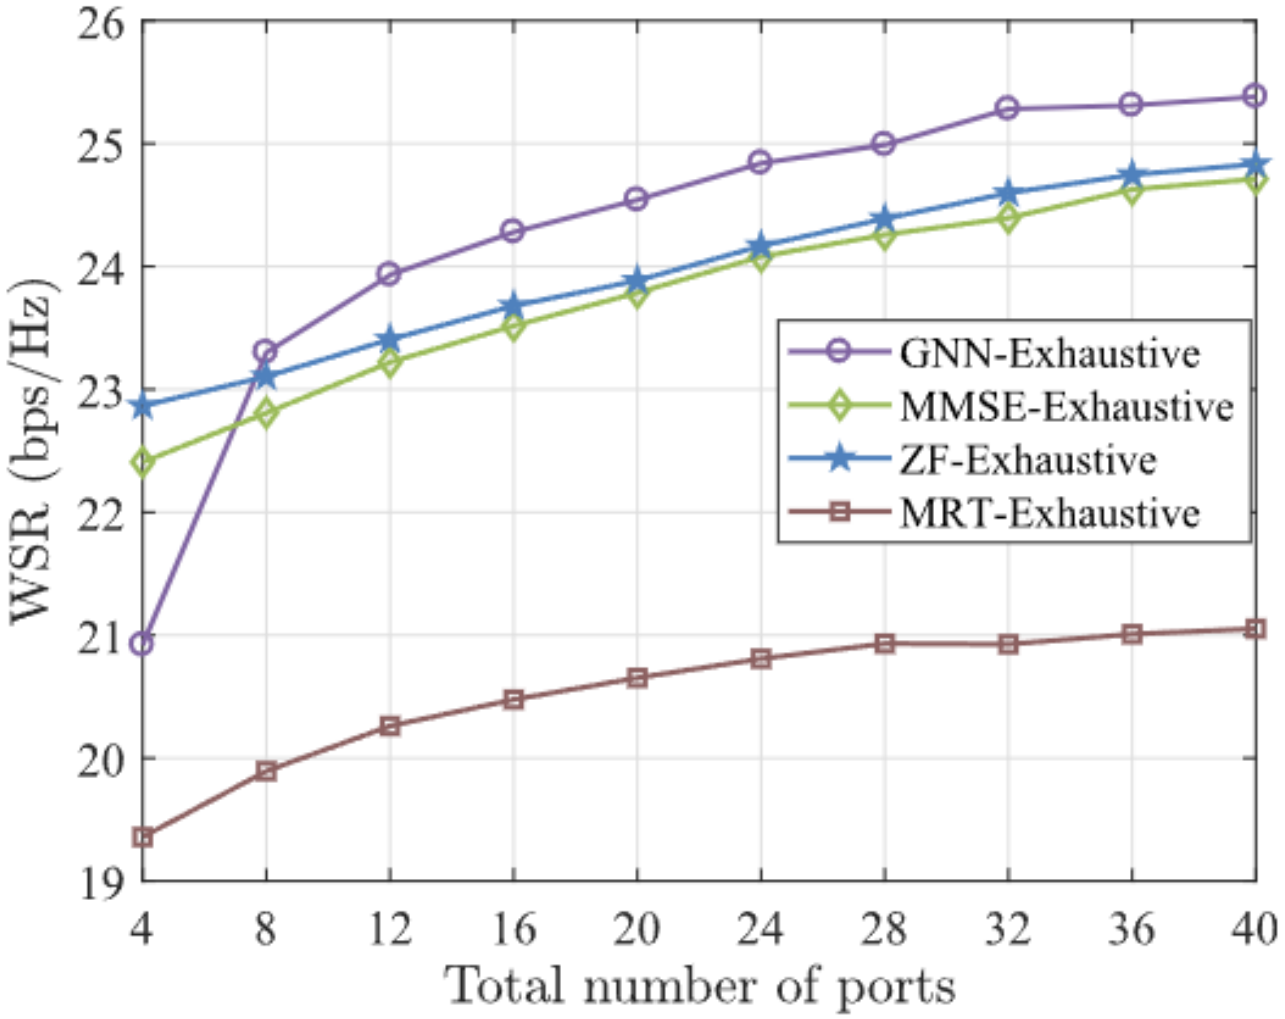

Fig. 10. The relationship between the WSR and the total number of ports.

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Resultados: Desempenho Computacional do FPGA

Plataforma usada

- Xilinx Virtex-7 XC7V690T
- Síntese com Vitis HLS 2022.2
- Precisão 8-bit fixed-point

Latência medida

- 1 seleção de porta:
  3.926 ms a 6.104 ms
- 4 seleções simultâneas:
  3.994 ms a 6.222 ms

Interpretação dos autores

- O sistema é memory-bound, não compute-bound
- Até 4 tarefas concorrentes, a latência cresce pouco
- Motivos:
  - reuso dos parâmetros da GNN já carregados
  - melhor utilização dos núcleos
  - menos acessos off-chip

Quando a paralelização deixa de ajudar tanto

- Para mais seleções de portas:
  - a latência cresce mais
  - o sistema passa a ficar compute-bound
  - o volume de dados intermediários pode exceder o armazenamento on-chip

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Análise crítica do trabalho

O que funcionou

- GNN-RPS superou MMSE, ZF e MRT na maioria dos cenários
- RPS com poucas tentativas já alcançou desempenho próximo do ótimo
- A GNN convergiu rapidamente e mostrou boa generalização
- O FPGA reduziu a latência e permitiu processar até 4 seleções quase sem aumento relevante

O que não funcionou tão bem

- Para L = 4 portas, a GNN ficou abaixo de ZF e MMSE
- A latência do FPGA ainda é de milissegundos, podendo ser acima do coherence time típico
- Quando o número de seleções cresce muito, o sistema deixa de ser memory-bound e a latência sobe bastante

O que ficou pouco claro no paper

- Não há comparação experimental direta com GPU moderna
- O paper não detalha o impacto de CSI imperfeito
- Não mostra análise de consumo energético total do sistema completo
- Não quantifica bem o custo de treinamento offline da multi-GNN
- Não explora em profundidade o limite prático do método em redes maiores

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

Conclusão

Síntese do que foi aprendido

- FAS aumenta os graus de liberdade espaciais por meio da seleção de portas
- O problema conjunto de beamforming + port selection é misto e não convexo
- O método GNN-RPS reduz a complexidade da otimização
- O uso de FPGA torna a inferência mais eficiente e mais próxima de aplicações práticas

Impacto do trabalho

- Integra otimização, aprendizado de máquina e hardware
- Mostra que co-design hardware-software é importante em FAS
- Supera métodos clássicos como MMSE, ZF e MRT
- Aproxima o tema de uma implementação mais realista em sistemas wireless

Direções futuras

- Melhorar a generalização da GNN
- Reduzir ainda mais a latência de inferência
- Explorar compressão de modelo e sparsity
- Investigar implementações em ASIC
- Avaliar cenários com CSI imperfeito e redes maiores

E, o mais importante:

Outros métodos para a seleção das portas

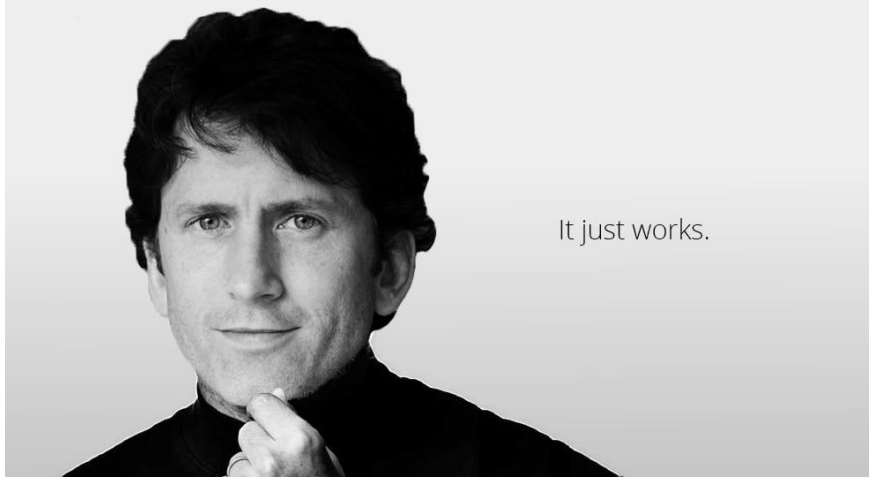

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.

RPS é bom mesmo?

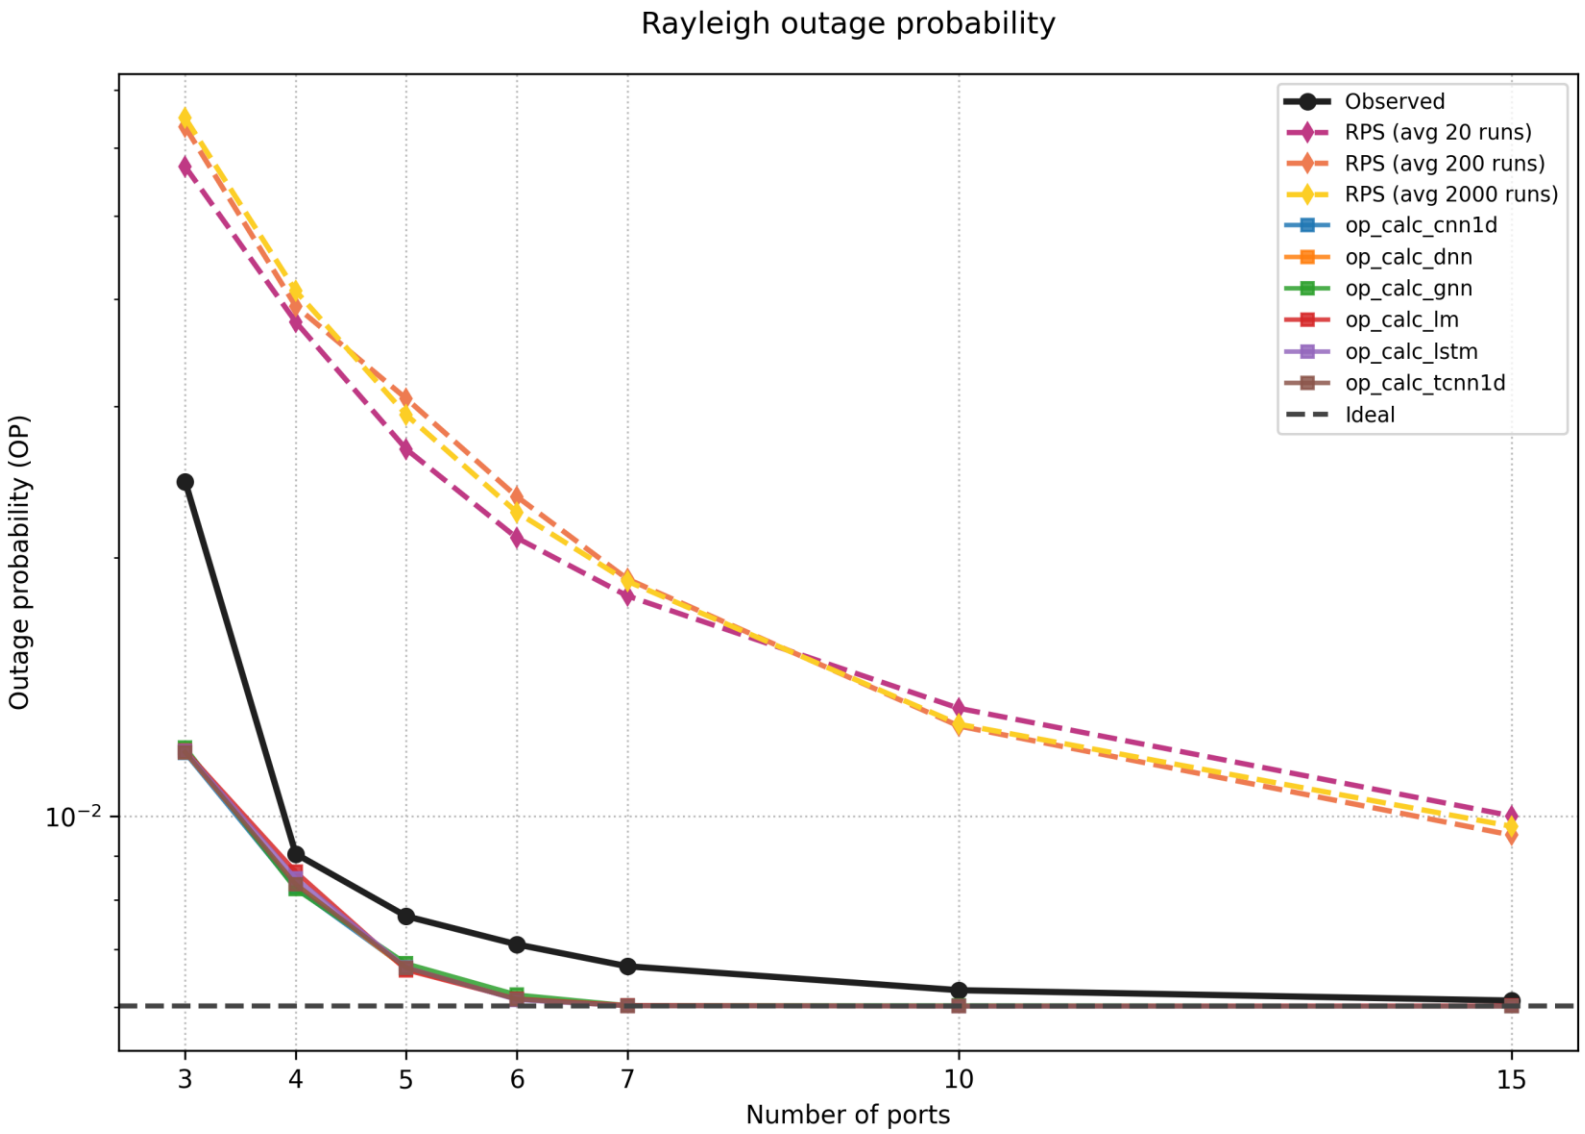

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.
Low-Power AI-Based Port Selection for Fluid Antennas in Spatially Correlated Channels, WCNPS 2025.

RPS é bom mesmo?

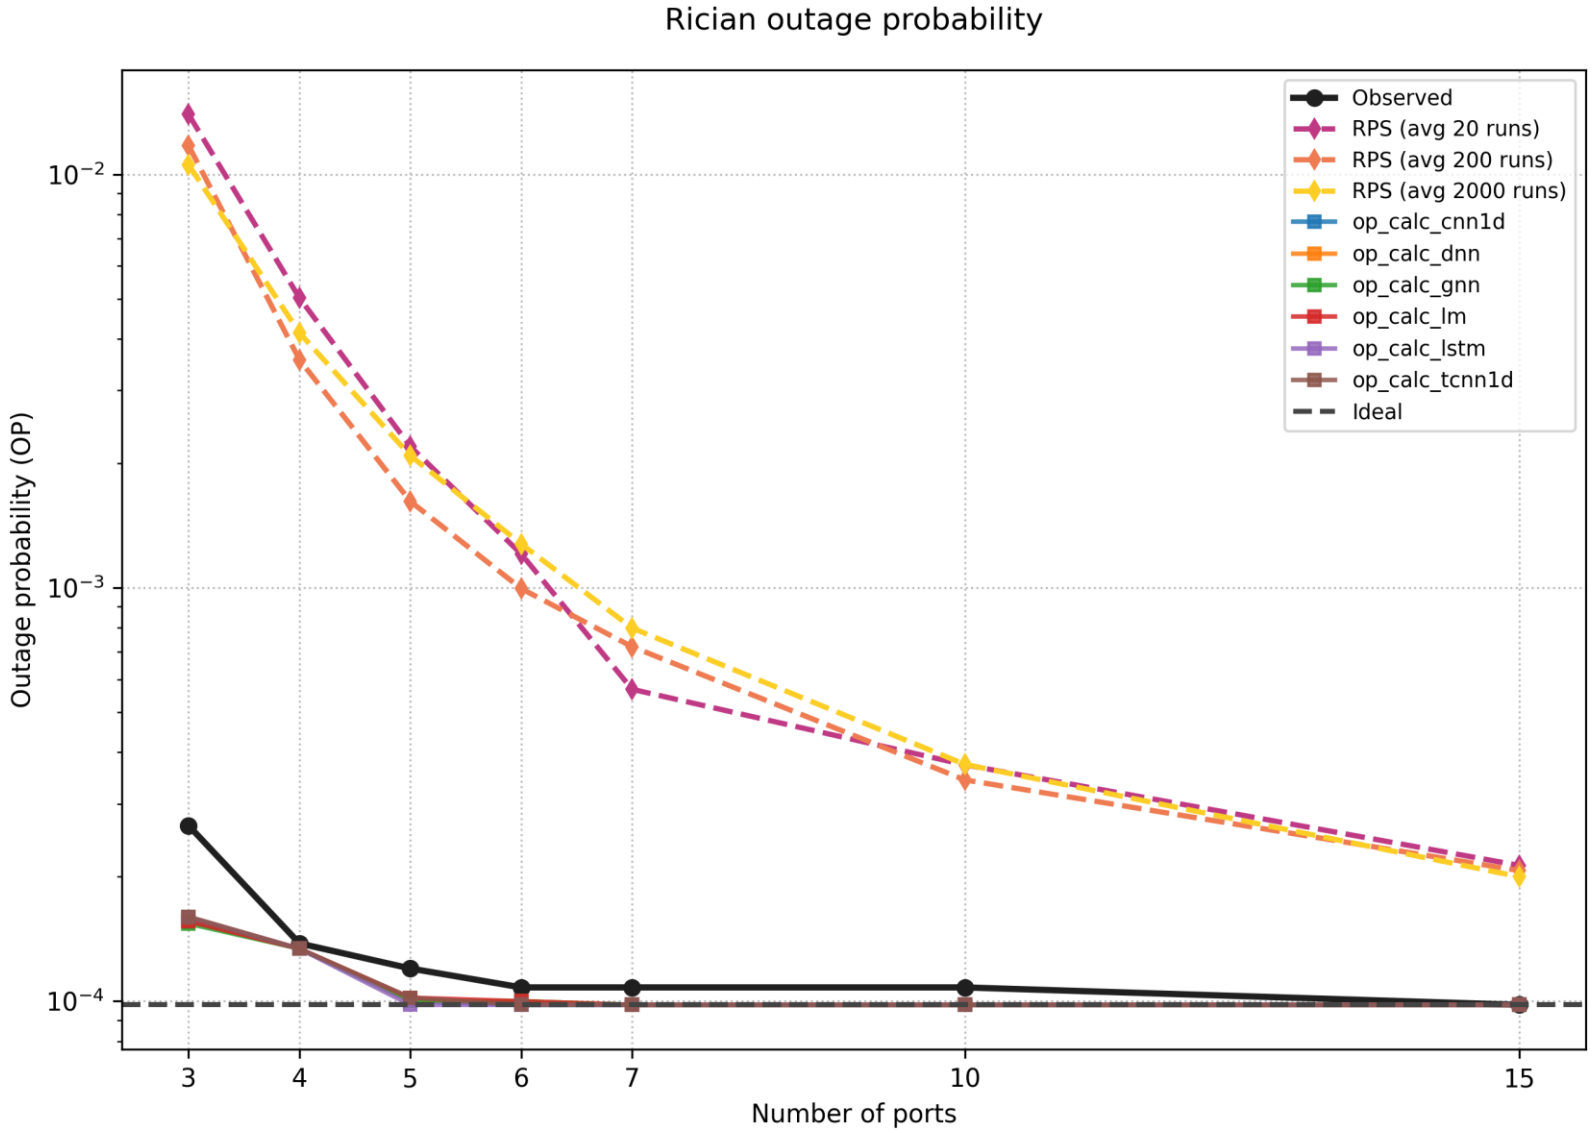

Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming, IEEE TWC, 2026.
Low-Power AI-Based Port Selection for Fluid Antennas in Spatially Correlated Channels, WCNPS 2025.

Perguntas?

Quiz

Toward Practical FAS - Seminário 01 - Matheus Ferreira Silva – Fill in form

Referências

•**[1]** S. Xu, K.-K. Wong, Y. Du, H. Hong, C.-B. Chae, B. Liu, and K.-F. Tong, “Toward Practical Fluid Antenna Systems: Co-Optimizing Hardware and Software for Port Selection and Beamforming,” *IEEE Transactions on Wireless Communications*, vol. 25, 2026.

•**[2]** W. K. New *et al*., “A tutorial on fluid antenna system for 6G networks: Encompassing communication theory, optimization methods and hardware designs,” *IEEE Communications Surveys & Tutorials*, vol. 27, no. 4, pp. 2325–2377, Aug. 2025.

•**[3]** K.-K. Wong, K.-F. Tong, Y. Zhang, and Z. Zhongbin, “Fluid antenna system for 6G: When Bruce Lee inspires wireless communications,” *Electronics Letters*, vol. 56, no. 24, pp. 1288–1290, Nov. 2020.

•**[4]** K.-K. Wong, K.-F. Tong, Y. Shen, Y. Chen, and Y. Zhang, “Bruce Lee-inspired fluid antenna system: Six research topics and the potentials for 6G,” *Frontiers in Communications and Networks*, vol. 3, Mar. 2022, Art. no. 853416.

•**[5]** S. Sanayei and A. Nosratinia, “Antenna selection in MIMO systems,” *IEEE Communications Magazine*, vol. 42, no. 10, pp. 68–73, Oct. 2004.

•**[6]** A. F. Molisch and M. Z. Win, “MIMO systems with antenna selection,” *IEEE Microwave Magazine*, vol. 5, no. 1, pp. 46–56, Mar. 2004.

•**[7]** K. K. Wong, A. Shojaeifard, K.-F. Tong, and Y. Zhang, “Performance limits of fluid antenna systems,” *IEEE Communications Letters*, vol. 24, no. 11, pp. 2469–2472, Nov. 2020.

•**[8]** K.-K. Wong, A. Shojaeifard, K.-F. Tong, and Y. Zhang, “Fluid antenna systems,” *IEEE Transactions on Wireless Communications*, vol. 20, no. 3, pp. 1950–1962, Mar. 2021.

•**[9]** Y. Shen *et al*., “Design and implementation of mmWave surface wave enabled fluid antennas and experimental results for fluid antenna multiple access,” arXiv:2405.09663, 2024.

Obrigado!