TP558 - Tópicos avançados em Machine Learning:

Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network

IEEE Global Communications Conference (Globecom) 2025

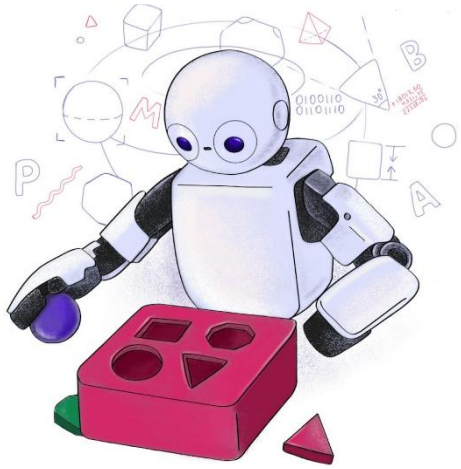

Inatel

Matheus Ferreira Silva
matheus.f@inatel.br

Contexto do Tema

- Surge conceito de **Fluid Antenna System (FAS)** para melhorar desempenho
- (2020) Kai Kit Wong

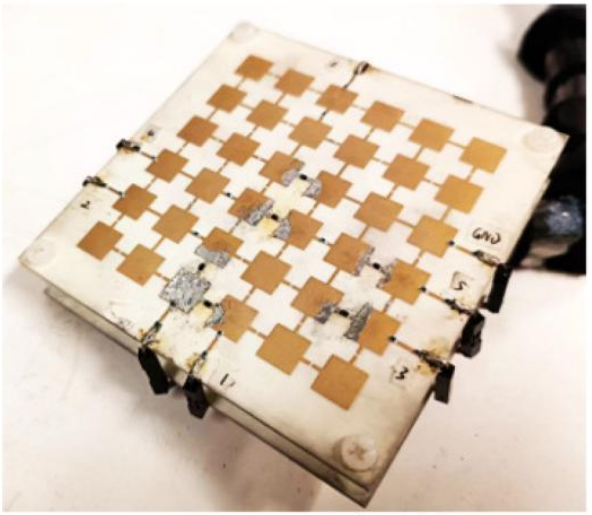

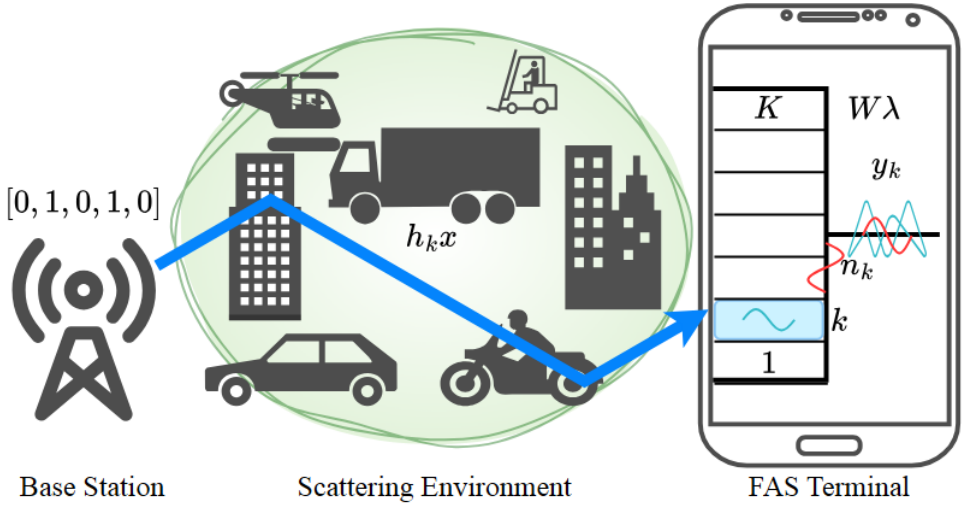

A relocalização da antena pode ser realizada movendo mecanicamente condutores líquidos por meio de um sistema microfluídico, ou ligando e desligando eletronicamente pixels radiantes.

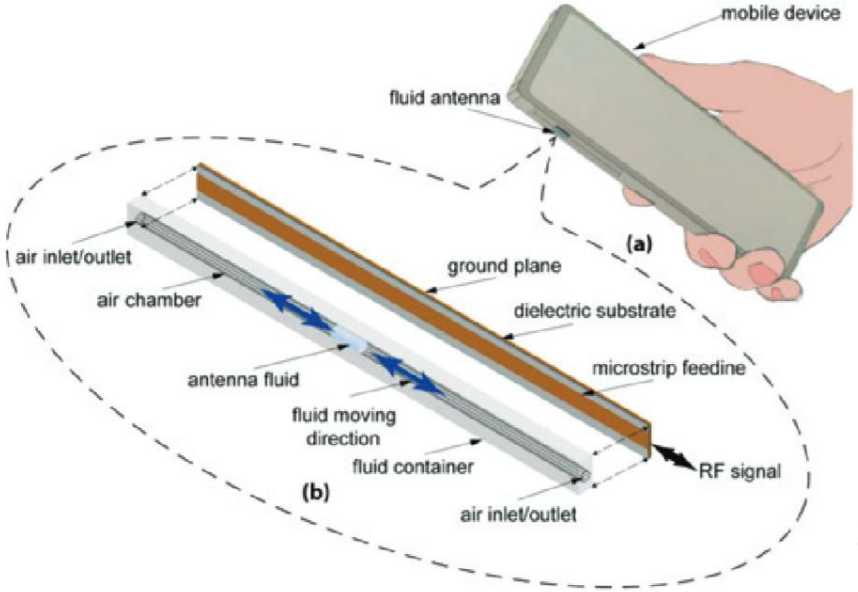

Low-Power AI-Based Port Selection for Fluid Antennas in Spatially Correlated Channels, WCNPS 2025.
Performance limits of fluid antenna systems, *IEEE Communications Letters*, Nov. 2020.
Fluid antenna system for 6G: When Bruce Lee inspires wireless communications, *Electronics Letters*, Nov. 2020.

Contexto do Tema

- No futuro, cada vez mais aplicações sem fio, serão implementadas com base em modelos de grandes dimensões (LMs).

- Desafio:
  - Usuários móveis têm restrições de processamento e latência.
  - Parte da inferência precisa ser executada em edge/cloud.
  - Isso aumenta o volume de dados transmitidos e a **latência** total do sistema.

Introdução do artigo

- Quantização reduz armazenamento e tráfego de dados. Porém, quantização agressiva degrada a qualidade das features.
- Surge então o trade-off central do artigo: **latência vs. qualidade da inferência**.

- Fluid antennas aumentam os graus de liberdade espaciais. Isso pode elevar a taxa uplink e reduzir o tempo de offloading.
- A ideia é aliviar a necessidade de quantização extrema.

Motivação do artigo:

- Projetar uma rede **LM-embedded MIMO assistida por fluid antennas** que minimize a latência total da rede, mantendo uma qualidade aceitável de inferência.

Fundamentação teórica

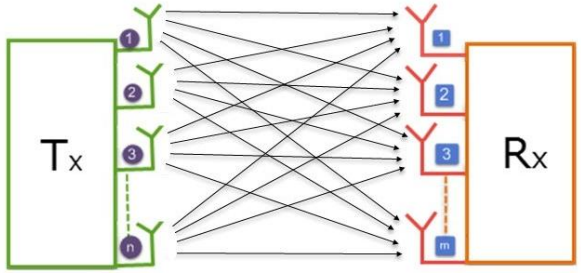

- **MIMO** é um sistema com múltiplas antenas no transmissor e/ou receptor. Permite maior eficiência espectral, diversidade e melhor exploração do canal sem fio.
- **LM-embedded network:** parte do processamento de um large model é integrada ao sistema de comunicação. O usuário executa uma etapa inicial e envia representações para processamento no edge/cloud.
- **Offloading de inferência: e**m vez de inferir tudo localmente, parte da inferência é transferida para um servidor. Adiciona latência de transmissão e processamento.
- **Edge AI** é o uso de técnicas de inteligência artificial próximas da fonte dos dados, como dispositivos finais, gateways ou servidores de borda, em vez de depender exclusivamente de processamento remoto em nuvem.
- **PSNR**, Peak Signal-to-Noise Ratio, é uma métrica que mede o quanto um sinal quantizado permanece próximo do original, onde valores maiores indicam menor erro e melhor qualidade.

Fundamentação teórica - Quantização em modelos neurais

Quantização é o processo de representar valores contínuos por um conjunto discreto de níveis, usando menos bits.

Por que isso importa em IA embarcada e edge?

- reduz memória e armazenamento,
- reduz volume de dados transmitidos,
- reduz custo computacional e latência,
- viabiliza inferência com precisão reduzida.

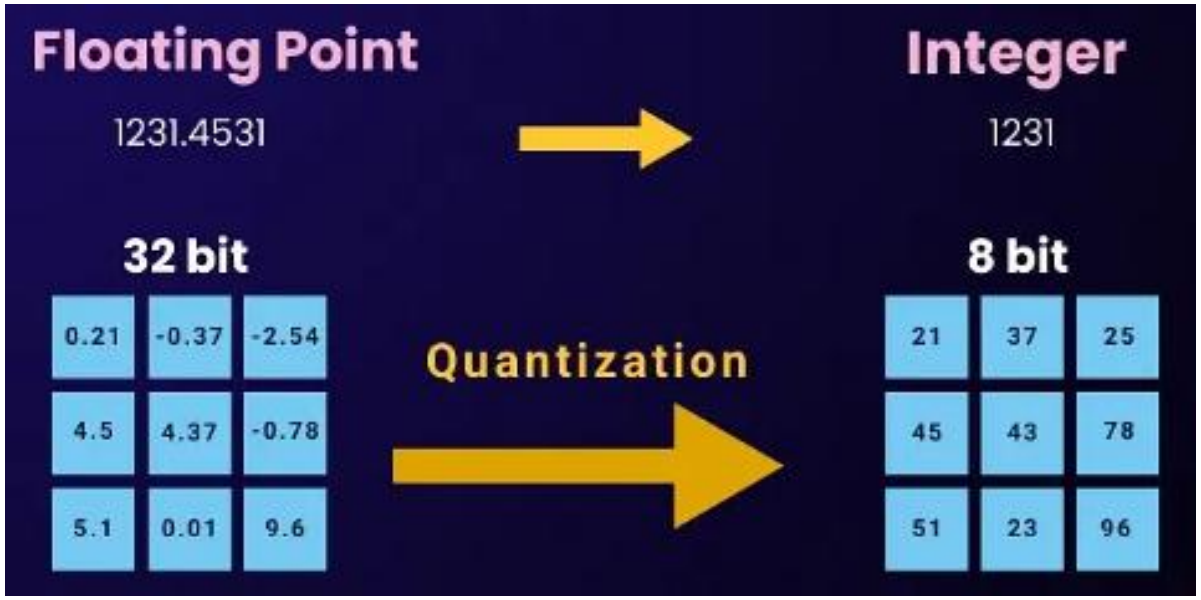

Precisão	Bits	Relação com FP32	Tamanho para 86M parâmetros
FP32	32	100%	0,344 GB
FP16 / BF16	16	50%	0,172 GB
INT8	8	25%	0,086 GB
INT4	4	12,5%	0,043 GB

NISHTHA. **LLM Quantization: Build and Optimize AI Models Efficiently**. ProjectPro, 20 jan. 2025.

Fundamentação teórica - LMs

Em geral, um Large Model é um modelo com grande número de parâmetros e alto custo de memória e computação, o que dificulta sua execução local em dispositivos com recursos limitados.

Exemplos:

- **BERT-Large**: **340M** parâmetros.
- **GPT-3**: **175B** parâmetros.
- **Llama 3.1 70B**: **70B** parâmetros
- **ViT-B/16**: cerca de **86M** parâmetros.

Trabalhos relacionados

Trabalhos sobre quantização de modelos

Ideia geral da literatura

- Aplicações sem fio futuras, como direção autônoma, tendem a incorporar large models para tarefas avançadas de percepção e decisão.
- Como esses modelos exigem alto poder computacional, a execução normalmente é deslocada para servidores de borda ou nuvem.

Limitação identificada

A literatura de contexto mostra por que LM em 6G é relevante, mas não resolve o principal gargalo prático: equilibrar **latência de rede** e **qualidade de inferência** em um sistema wireless real

Trabalhos relacionados

Literatura de quantização, reduzir latência sem inflar comunicação

Ideia geral da literatura

- Quantização reduz custo de transmissão e armazenamento.
- Menos bits, menor volume de dados, menor latência de offloading.
- É uma solução natural para cenários de edge inference.
- Porém, quantização agressiva pode degradar fortemente a qualidade da inferência.

Limitação identificada

A literatura trata bem a redução de latência, mas não resolve adequadamente o conflito entre **compressão agressiva** e **perda de acurácia**.

Trabalhos relacionados

Literatura de fluid antenna, aumentar taxa sem depender só de quantização

Ideia geral da literatura

- A fluid antenna ajusta a posição física dos elementos radiantes.
- Isso aumenta os graus de liberdade espaciais do sistema.
- Com melhor canal e maior taxa de transmissão, o offloading fica mais rápido.
- Assim, é possível reduzir latência sem depender exclusivamente de quantização agressiva.

Limitação identificada

A literatura mostra que fluid antenna pode aumentar a taxa e reduzir a latência de offloading, mas ainda não entrega um framework completo para inferência LM-embedded que otimize, de forma conjunta, comunicação e qualidade das features.

Trabalhos relacionados

Literatura mais próxima, FA aplicada a learning e federated learning

Ideia geral da literatura

Já existem trabalhos pioneiros usando fluid antenna em sistemas de aprendizado sem fio, principalmente em cenários de treinamento e federated learning.

Limitação identificada

- Foco principal na fase de treinamento, não na inferência.
- Hipótese de usuários com antena única.
- Ausência de análise para cenários mais práticos com usuários multiantena.
- Não tratam explicitamente o problema conjunto de latência e qualidade de inferência.

ViT-B-16

16.9 GMACs

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

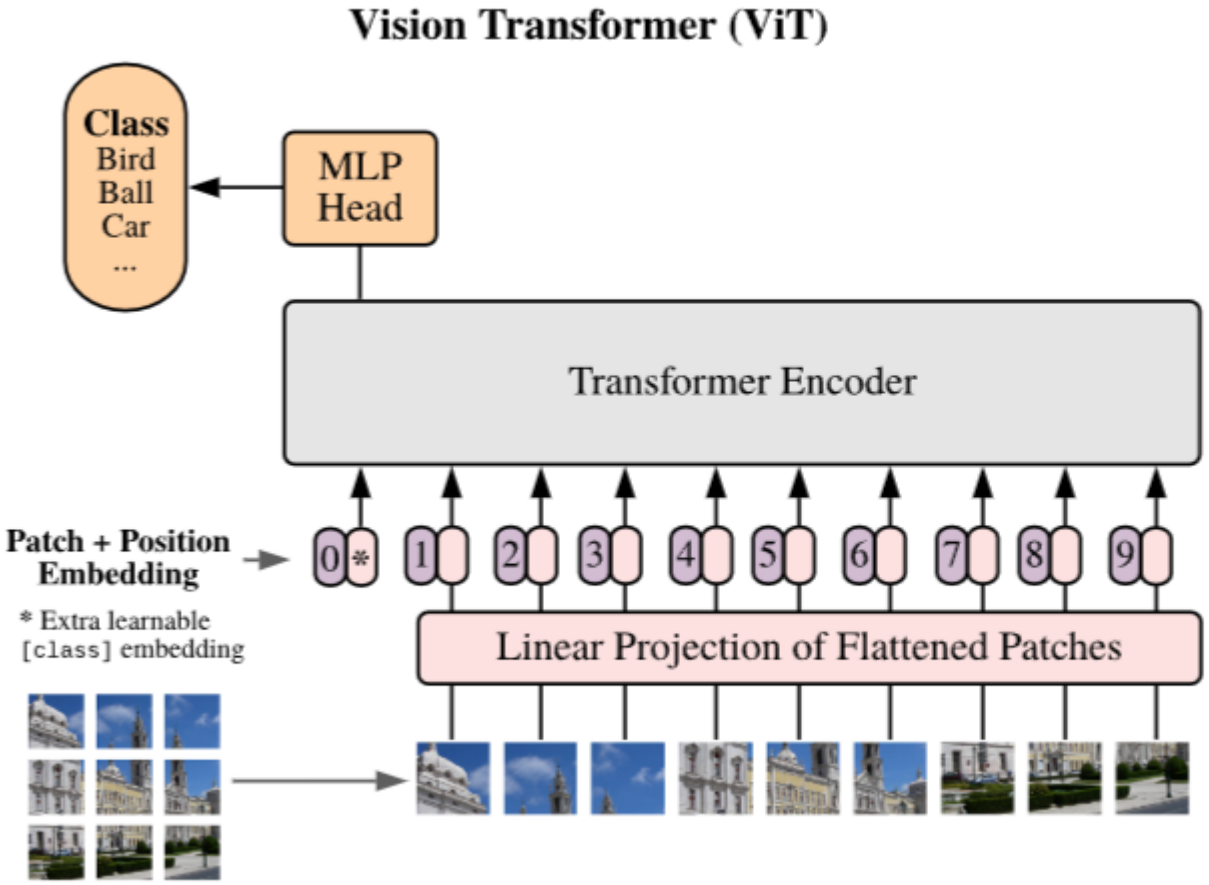

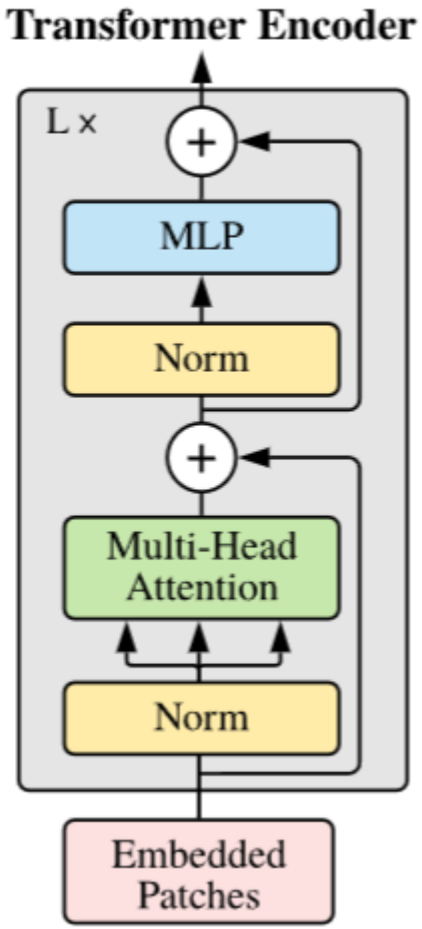

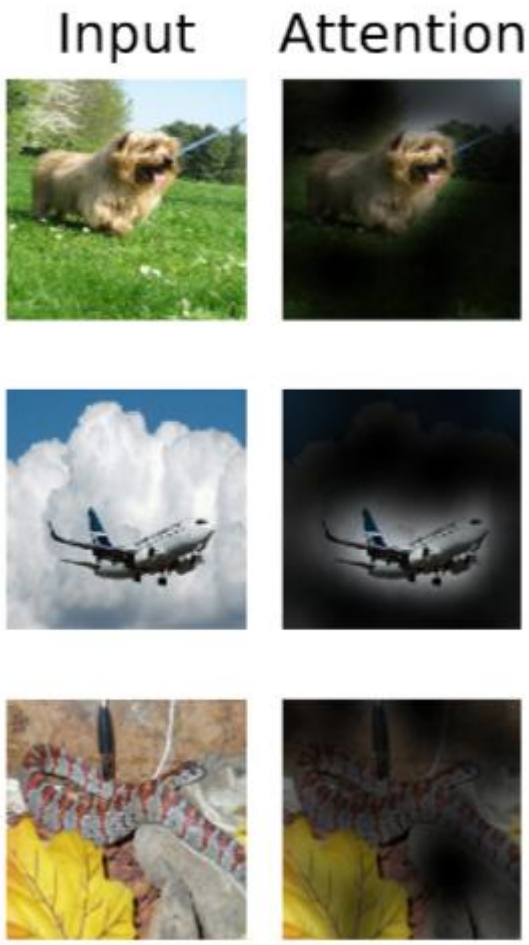

A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2021.

Modelo de Sistema

A posição da antena a do usuário u é:

$$\mathbf{t}_{u,a} \triangleq \begin{bmatrix} x^t_{u,a} \\ y^t_{u,a} \end{bmatrix}$$

- $\mathbf{t}_{u,a}$, vetor posição da antena a do usuário u
- $x^t_{u,a}$, coordenada x dessa antena do usuário
- $y^t_{u,a}$, coordenada y dessa antena do usuário
- $u \in \mathcal{U}$, índice do usuário
- $a \in \mathcal{A}$, índice da antena do usuário

O paper agrupa todas essas posições em uma matriz:

$$\mathbf{T} = [\mathbf{t}_{1,1}, \mathbf{t}_{1,2}, \ldots, \mathbf{t}_{1,A}, \mathbf{t}_{2,1}, \ldots, \mathbf{t}_{U,A}]$$

A posição da fluid antenna m da BS é:

$$\mathbf{r}_m \triangleq \begin{bmatrix} x^r_m \\ y^r_m \end{bmatrix}$$

e a matriz de posições da BS é:

$$\mathbf{R} = [\mathbf{r}_1, \mathbf{r}_2, \ldots, \mathbf{r}_M]$$

- $\mathbf{r}_m$, posição da FA m da BS
- x^r_m, coordenada x da FA m
- y^r_m, coordenada y da FA m
- $\mathbf{R}$, matriz com todas as posições das FAs da BS
- $m \in \mathcal{M}$, índice da FA na BS

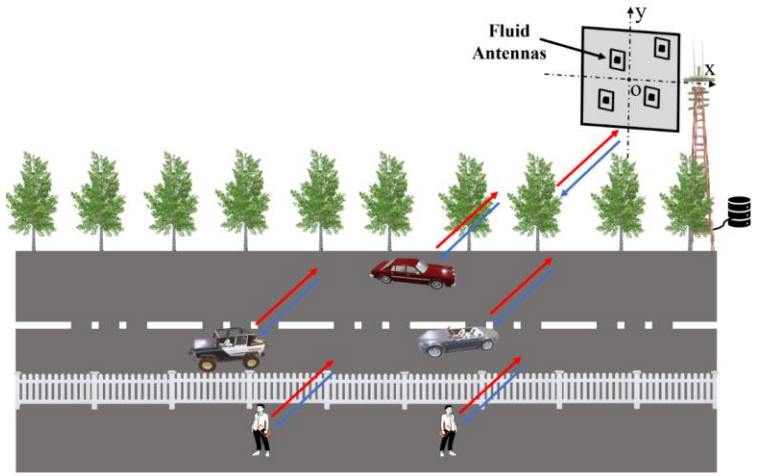

- Rede MIMO
- **Uma base station, BS**, equipada com M fluid antenas
- Cada usuário (U) possui A antenas **fixas**. Número de antenas dos usuários não ultrapassa o númerod de FAs: **UA≤M**
- **Um servidor**, responsável pela inferência do large model
- **Space-division multiple access:** vários usuários podem se comunicar com a BS ao mesmo tempo
- Assume-se que o tempo necessário para o ajuste das posições de FA é **desprezível**.

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Modelo de canal: **narrow-band**, **quasi-static** e **far-field**

$$\mathbf{F}(\mathbf{R}) = [\mathbf{f}_1(\mathbf{R}), \mathbf{f}_2(\mathbf{R}), \ldots, \mathbf{f}_U(\mathbf{R})]$$

onde:

$$\mathbf{f}_u(\mathbf{R}) = \begin{bmatrix} \exp\left(j\frac{2\pi}{\lambda}\rho_u(\mathbf{r}_1)\right) \\ \vdots \\ \exp\left(j\frac{2\pi}{\lambda}\rho_u(\mathbf{r}_M)\right) \end{bmatrix}$$

e

$$\rho_u(\mathbf{r}_m) \triangleq x_m^r \sin\theta_u^r \cos\phi_u^r + y_m^r \cos\theta_u^r$$

- $\mathbf{F}(\mathbf{R})$, matriz de resposta espacial da BS
- $\mathbf{f}_u(\mathbf{R})$, vetor resposta espacial da BS para o usuário u
- j, unidade imaginária
- λ, comprimento de onda da portadora
- $\rho_u(\mathbf{r}_m)$, termo geométrico de fase associado à posição da FA m
- x_m^r, y_m^r, coordenadas da FA m
- θ_u^r, ângulo de elevação de chegada do sinal do usuário u
- ϕ_u^r, ângulo de azimute de chegada do sinal do usuário u

$$\mathbf{G} = [\mathbf{g}_1, \mathbf{g}_2, \ldots, \mathbf{g}_U]$$

com

$$\mathbf{g}_u = \begin{bmatrix} \exp\left(j\frac{2\pi}{\lambda}\rho_{u,a}\right) \\ \vdots \\ \exp\left(j\frac{2\pi}{\lambda}\rho_{u,A}\right) \end{bmatrix}$$

e

$$\rho_{u,a} \triangleq x_{u,a}^t \sin\theta_u^t \cos\phi_u^t + y_{u,a}^t \cos\theta_u^t$$

- $\mathbf{G}$, matriz de steering dos usuários
- $\mathbf{g}_u$, vetor resposta espacial das antenas do usuário u
- $\rho_{u,a}$, termo geométrico da antena a do usuário u
- $x_{u,a}^t, y_{u,a}^t$, coordenadas da antena a do usuário u
- θ_u^t, ângulo de elevação de saída do usuário u
- ϕ_u^t, ângulo de azimute de saída do usuário u
- A, número de antenas por usuário

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Outras definições

A taxa uplink do usuário u é dada por:

$$R_{ul,u} = \log_2 \det \left(\mathbf{I}_A + \mathbf{W}_u^H \mathbf{H}_u \mathbf{P}_u^{1/2} \mathbf{Z}_{ul,u}^{-1} \mathbf{P}_u^{1/2} \mathbf{H}_u^H \mathbf{W}_u \right)$$

onde

$$\mathbf{W}_u = [\mathbf{w}_{u,1}, \mathbf{w}_{u,2}, \ldots, \mathbf{w}_{u,A}]$$

$$\mathbf{P}_u^{1/2} = \mathrm{diag}[\sqrt{p_{u,1}}, \sqrt{p_{u,2}}, \ldots, \sqrt{p_{u,A}}]$$

e a covariância de interferência mais ruído é:

$$\mathbf{Z}_{ul,u} = \sigma^2 \mathbf{W}_u^H \mathbf{W}_u + \sum_{k \in \mathcal{U}, k \neq u} \mathbf{W}_u^H \mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^H \mathbf{W}_u$$

- $R_{ul,u}$, taxa uplink do usuário u
- $\log_2 \det(\cdot)$, fórmula típica de taxa para canal MIMO gaussiano
- $\mathbf{I}_A$, identidade de dimensão A
- $\mathbf{W}_u$, beamforming de recepção associado ao usuário u
- $\mathbf{H}_u$, canal do usuário u
- $\mathbf{P}_u^{1/2}$, matriz diagonal com as raízes das potências do usuário u
- $\mathbf{Z}_{ul,u}$, covariância de interferência mais ruído vista pelo usuário u
- $\mathbf{P}_k$, potência do usuário interferente k
- σ^2, variância do ruído
- $k \neq u$, todos os outros usuários interferentes

$$\mathbf{W} = [\mathbf{w}_{1,1}, \mathbf{w}_{1,2}, \ldots, \mathbf{w}_{U,A}]$$

$$\mathbf{H}(\mathbf{R}) = [\mathbf{H}_1, \mathbf{H}_2, \ldots, \mathbf{H}_U]$$

$$\mathbf{P} = \mathrm{diag}[p_{1,1}, p_{1,2}, \ldots, p_{U,A}]$$

$$\mathbb{E}\{\mathbf{s}\mathbf{s}^H\} = \mathbf{I}_{UA}$$

$$\mathbf{n} \sim \mathcal{CN}(0, \sigma^2 \mathbf{I}_M)$$

- $\mathbf{w}_{u,a}$, vetor de beamforming associado à antena a do usuário u
- $\mathbf{H}_u$, canal do usuário u
- $p_{u,a}$, potência transmitida pela antena a do usuário u
- $\mathbb{E}\{\cdot\}$, operador esperança
- $\mathbf{I}_{UA}$, matriz identidade de dimensão UA
- $\mathcal{CN}(0, \sigma^2 \mathbf{I}_M)$, distribuição gaussiana complexa circular com média zero e covariância $\sigma^2 \mathbf{I}_M$
- σ^2, variância do ruído
- M, número de FAs na BS

$$\mathbf{y}^{ul} = \mathbf{W}^H \mathbf{H}(\mathbf{R}) \mathbf{P}^{1/2} \mathbf{s} + \mathbf{W}^H \mathbf{n}$$

- $\mathbf{y}^{ul}$, sinal uplink recebido na BS após beamforming
- $\mathbf{W}$, matriz de receive beamforming
- $\mathbf{W}^H$, transposta conjugada de $\mathbf{W}$
- $\mathbf{H}(\mathbf{R})$, canal completo do sistema, dependente das posições das FAs
- $\mathbf{P}^{1/2}$, raiz quadrada da matriz diagonal de potências dos usuários
- $\mathbf{s}$, vetor de sinais transmitidos pelos usuários
- $\mathbf{n}$, ruído branco gaussiano aditivo
- ul, uplink

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Quantization

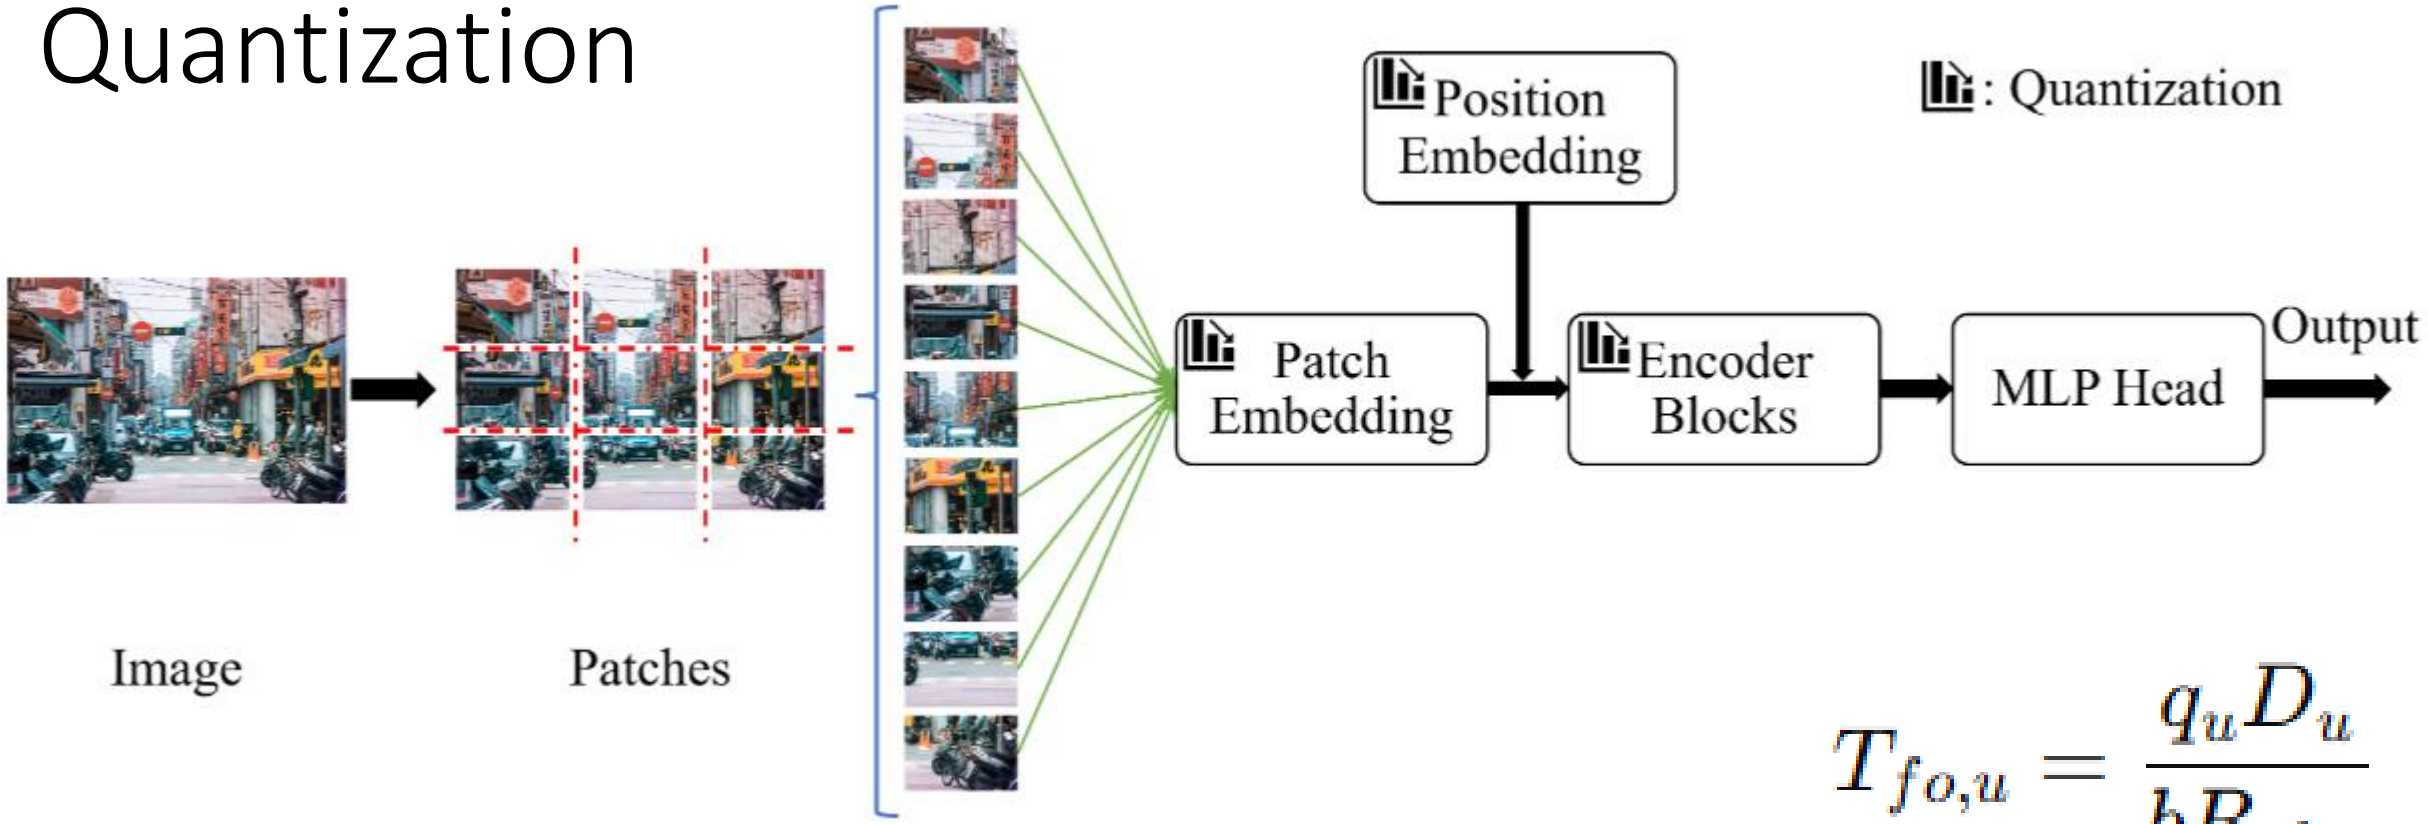

$$T_{fo,u} = \frac{q_u D_u}{b R_{ul,u}}$$

cliente executa embedding → quantiza → envia ao servidor → servidor faz a inferência

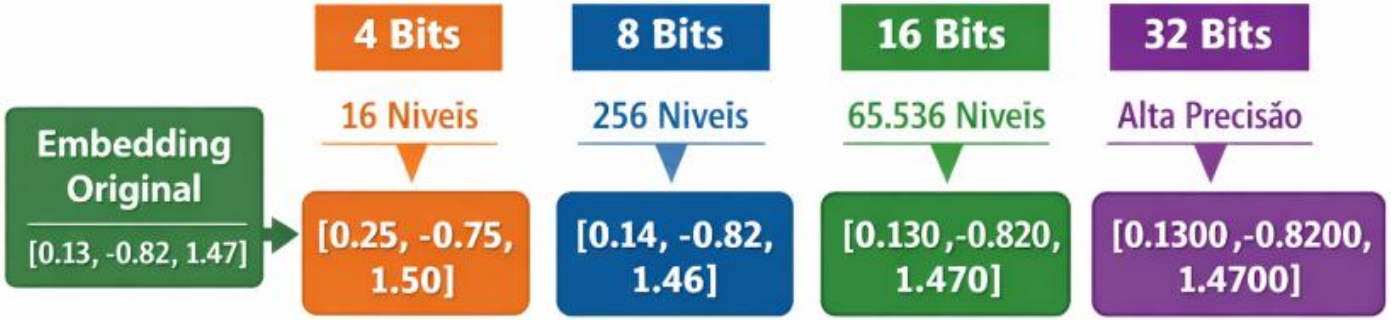

Onde D_u é o tamanho das features, b é a largura de banda e $R_{ul,u}$ é a taxa uplink do usuário.

$$q_u \in \{4, 8, 16, 32\}$$

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, "Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network," *arXiv preprint* arXiv:2508.01689, 2025.

Outras definições

$$\Delta = \frac{x_{\max} - x_{\min}}{2^{q_u} - 1}$$

- Δ, passo de quantização
- $x_{\max}$, valor máximo dos dados
- $x_{\min}$, valor mínimo dos dados
- q_u, número de bits de quantização do usuário u

Assumindo que o erro de quantização é uniforme em $[-\Delta/2, \Delta/2]$, a potência do erro é:

$$\sigma_e^2 = \frac{\Delta^2}{12}$$

- σ_e^2, potência do erro de quantização
- Δ, passo de quantização

$$T = \sum_{u=1}^{U} (T_{fo,u} + T_{si,u})$$

- T, latência total do sistema
- $T_{fo,u}$, latência de offloading das features do usuário u
- $T_{si,u}$, latência de inferência no servidor para o usuário u
- U, número de usuários

O PSNR do usuário u é definido como:

$$\mathrm{PSNR}_u \triangleq 10 \log_{10} \left(\frac{\sigma_{x_{\max}}^2}{\sigma_e^2} \right)$$

e o PSNR total do sistema é:

$$\mathrm{PSNR} = \sum_{u=1}^{U} \mathrm{PSNR}_u$$

- PSNR_u, PSNR da feature quantizada do usuário u
- $\sigma_{x_{\max}}^2$, valor máximo das features, ou potência máxima usada na definição do PSNR
- σ_e^2, potência do erro de quantização
- PSNR, PSNR total do sistema
- U, número de usuários

A latência de inferência do usuário u no servidor é:

$$T_{si,u} = \frac{c_s d_u}{f_{s,u}}$$

- $T_{si,u}$, latência de inferência do usuário u no servidor
- c_s, número de ciclos de processamento por parâmetro no servidor
- d_u, tamanho do large model associado ao usuário u, em número de parâmetros
- $f_{s,u}$, frequência de processamento do servidor alocada ao usuário u

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

A função objetivo

A função loss do paper é:

$$\text{Loss}\left(\{\mathbf{r}_m\}_{m=1}^{M}, \{\mathbf{w}_{u,a}\}_{u=1,a=1}^{U,A}, \mathbf{f}_s, \mathbf{q}\right) = T - \alpha \cdot \text{PSNR}$$

- Loss, função objetivo a ser minimizada
- $\{\mathbf{r}_m\}_{m=1}^{M}$, posições das fluid antennas da BS
- $\{\mathbf{w}_{u,a}\}_{u=1,a=1}^{U,A}$, vetores de beamforming de recepção
- $\mathbf{f}_s$, vetor com frequências de processamento do servidor alocadas aos usuários
- $\mathbf{q}$, vetor com os bits de quantização dos usuários
- T, latência total do sistema
- α, fator de sensibilidade do desempenho do LM à quantização
- PSNR, qualidade total das features quantizadas

$$\mathcal{P}: \quad \min_{\{\mathbf{r}_m\},\{\mathbf{w}_{u,a}\},\mathbf{f}_s,\mathbf{q}} \text{Loss}$$

$$\sum_{u=1}^{U} f_{s,u} \leq f_{ser}$$

$$\mathbf{r}_m \in \mathcal{C}_R, \quad \forall m \in \mathcal{M}$$

$$\|\mathbf{r}_m - \mathbf{r}_l\|_2 \geq D, \quad \forall m, l \in \mathcal{M},\ m \neq l$$

$$q_u \in \{4, 8, 16, 32\}, \quad \forall u \in \mathcal{U}$$

$$\|\mathbf{w}_{u,a}\|_2 = 1, \quad \forall u \in \mathcal{U},\ \forall a \in \mathcal{A}$$

$f_{s,u}$, frequência de processamento do servidor alocada ao usuário u

f_{ser}, orçamento total de capacidade computacional do servidor

U, número de usuários

$\mathbf{r}_m$, posição da FA m

$\mathcal{C}_R$, região física do painel da antena onde a FA pode se mover

$\|\mathbf{r}_m - \mathbf{r}_l\|_2$, distância euclidiana entre duas FAs

D, distância mínima exigida entre antenas

m, l, índices das FAs da BS

$\mathbf{w}_{u,a}$, vetor de beamforming da antena a do usuário u

$\|\mathbf{w}_{u,a}\|_2$, norma Euclidiana do vetor de beamforming

q_u, bits de quantização do usuário u

A solução

Embora o problema original seja difícil, **as restrições de cada bloco de variáveis são separáveis**. Por isso, eles adotam **BCD**, isto é, em vez de otimizar todas as variáveis ao mesmo tempo, eles:

1. **fixam todas as outras,**
2. **escolhem um bloco de variáveis,**
3. **resolvem esse subproblema,**
4. **passam para o próximo bloco,**
5. **repetem iterativamente.**

$\mathbf{f}_s$, frequências de processamento do servidor

$\mathbf{q}$, bits de quantização

$\{\mathbf{w}_{u,a}\}_{u=1,\,a=1}^{U,\,A}$, beamforming de recepção

$\{\mathbf{r}_m\}_{m=1}^{M}$, posições das fluid antennas

Algorithm 1 The Overall Algorithm for Solving $\mathcal{P}$

```
Initialize all variables
repeat
    for u = 1, ..., U do
        Update f_{s,u} based on (13).
    end for
    Update q by the Lemma 2 and (15).
    repeat
        Update {w_{u,a}}_{u=1,a=1}^{U,A} via sequentially update W,
        W', and λ based on (18), (19) and (20).
    until Stopping criterion is satisfied.
    Update {r_m}_{m=1}^{M} by sequentially solving P4 − m.
until Stopping criterion is satisfied.
```

Os subproblemas

P1: Alocação de processamento do servidor
Distribui a capacidade computacional total do servidor entre os usuários. Os autores conseguem obter uma solução fechada usando as condições Karush-Kuhn-Tucker (KKT).

P2: Escolha dos bits de quantização
Define quantos bits cada usuário deve usar para equilibrar latência e qualidade.

P3: Beamforming de recepção
Ajusta os filtros da BS para melhorar a taxa uplink e reduzir interferência. Usam uma reformulação com Riemannian Alternating Direction Method of Multipliers (RADMM).

P4: Posicionamento das fluid antennas
Move as antenas da BS dentro do painel para melhorar o canal, respeitando as restrições físicas.

Resultados

- **Critério de parada:** variação relativa da função objetivo menor que 10^{-3}
- **Número de usuários:** $U = 3$
- **Antenas por usuário:** $A = 2$
- **Antenas na BS:** $M = 6$
- **Painel das FAs:** área quadrada $L \times L$
- **Distância mínima entre FAs:** $D = \lambda/2$
- **Comprimento de onda:** $\lambda = 0.05$
- **Canal:** Rician com fator $K_u = 1$
- **Componente NLOS:** $N = 5$ espalhadores
- **Ângulos de elevação e azimute:** i.i.d. uniformes em $[0, \pi)$
- **SNR de transmissão:** $P/\sigma^2 = 10$ dB
- **Ruído:** $\sigma^2 = 1$
- **Plataforma:** Monte Carlo em Matlab R2024a
- **RADMM:** ρ inicial = 5, multiplicado por 1.2
- **Fator de sensibilidade:** $\alpha = 0.02$, para LM com 1 bilhão de parâmetros

Resultados

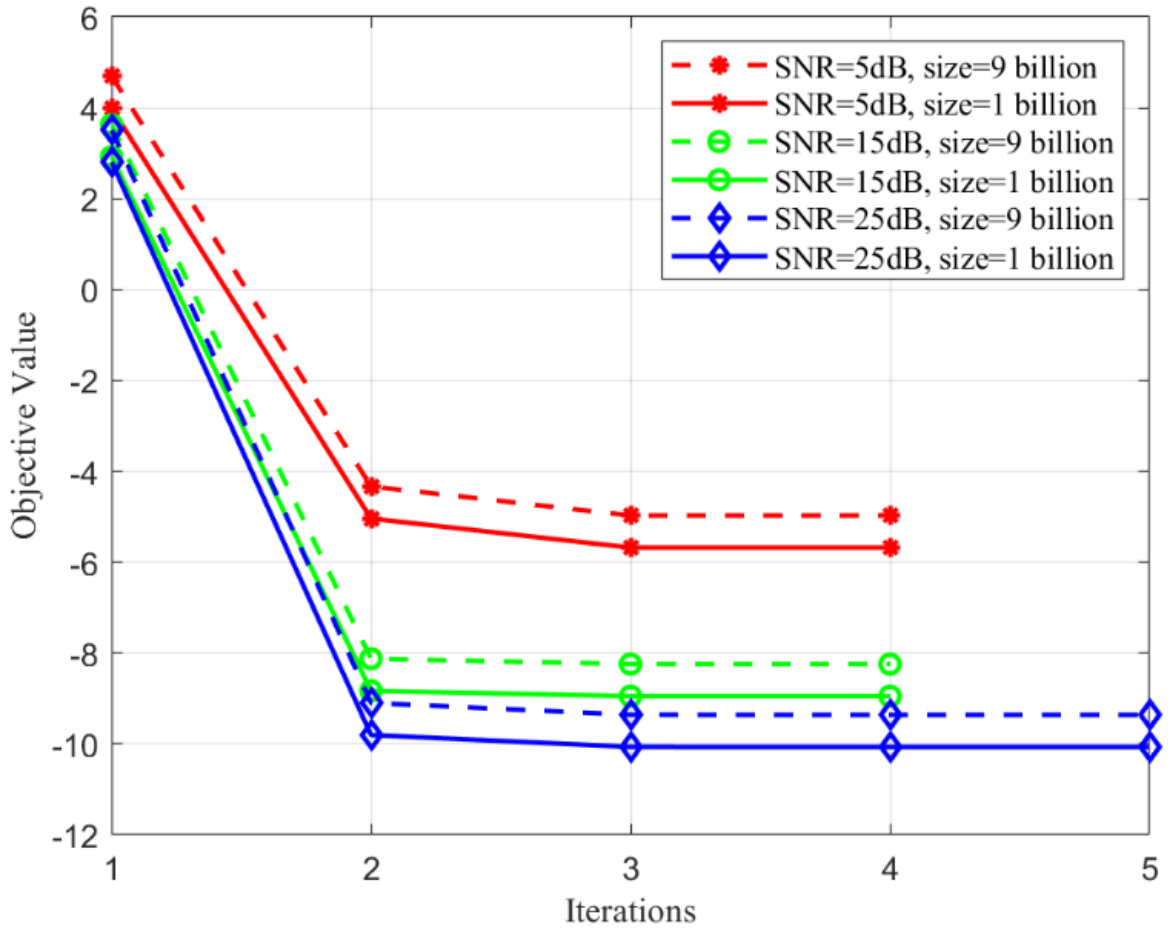

Fig. 3. The convergence behavior of the objective function of $\mathcal{P}$.

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Resultados

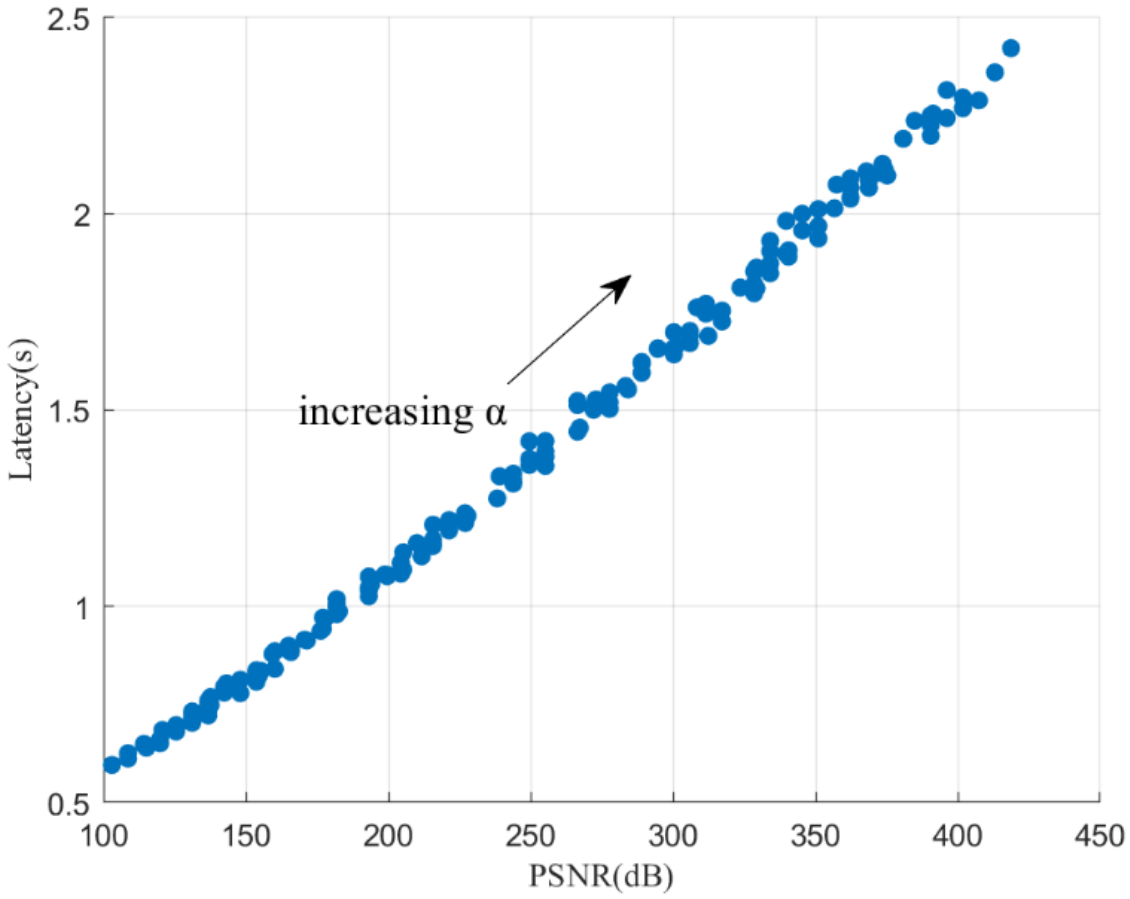

Fig. 4. The illustration of PSNR and latency with increasing α.

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Resultados

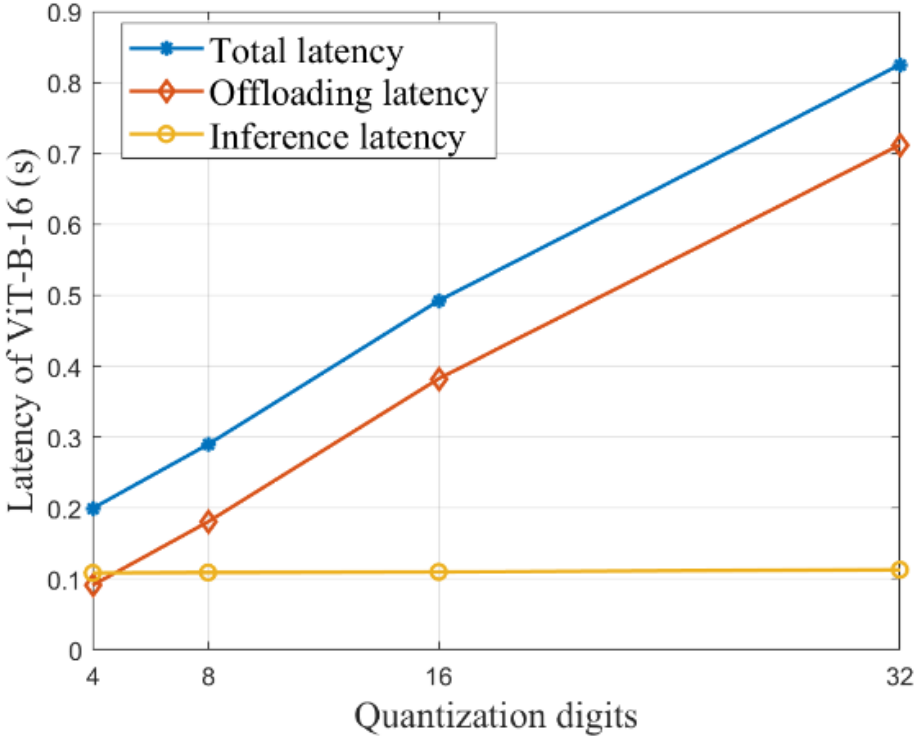

(a)

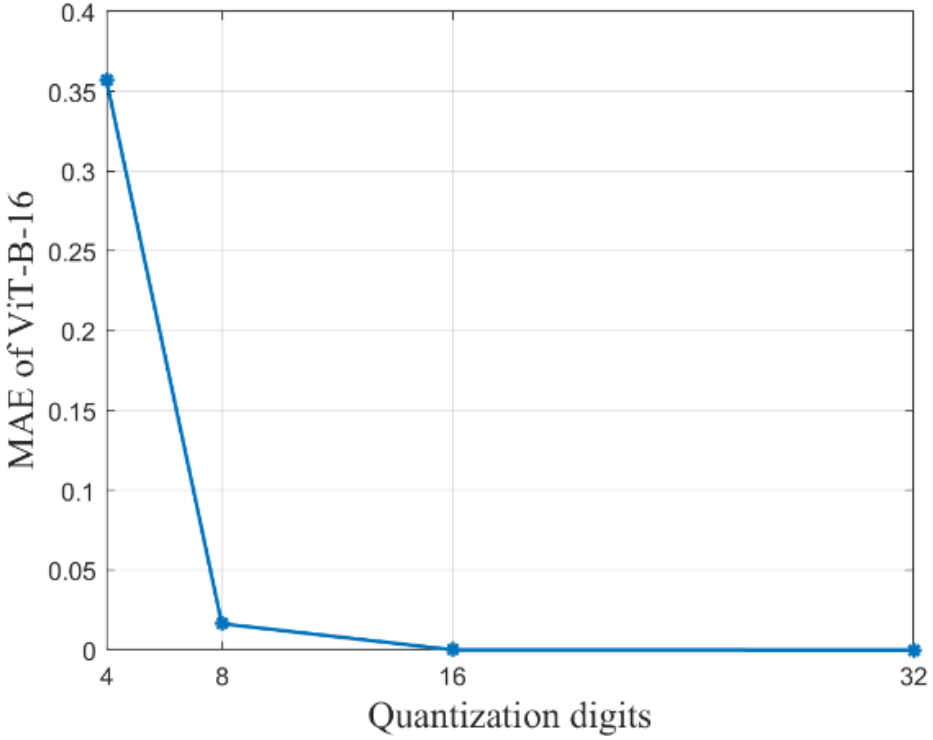

(b)

Fig. 5. The illustration of the performance of ViT-B-16-embedded system versus the quantization digits.

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Resultados

- $U = 2$
- $L = 10\lambda$

FAs: fluid antennas

FPA system: fixed-position antenna system, baseline

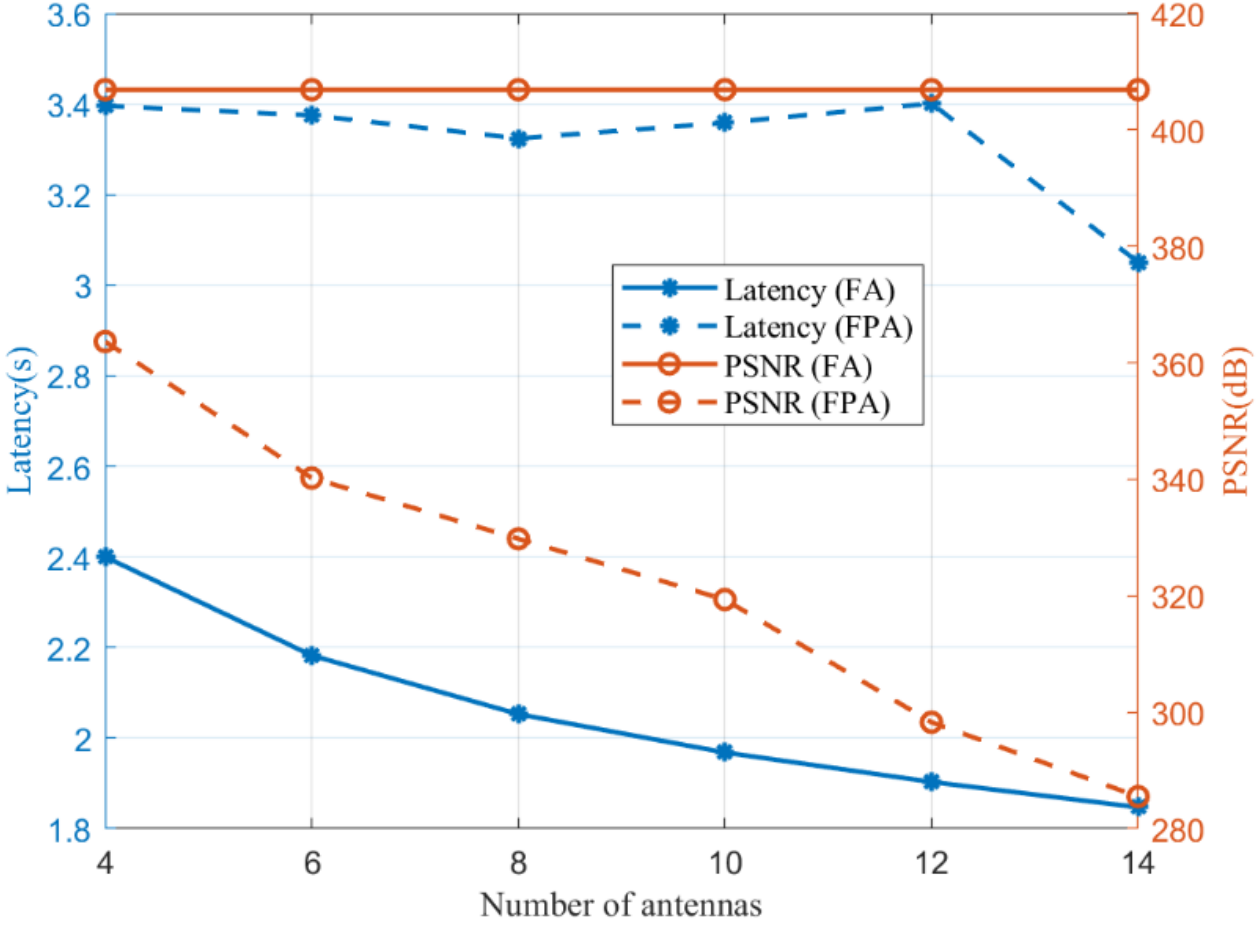

Fig. 6. The illustration of the system performance versus M.

Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.

Conclusões

1. Conclusões dos autores

- O paper formula o trade-off entre latência e acurácia de inferência como um problema não convexo, acoplado e misto-inteiro.
- Propõe um sistema FA-assisted LM-embedded MIMO com função objetivo baseada em latência total + qualidade das features quantizadas.
- O algoritmo proposto converge rapidamente e mostra ganhos sobre os benchmarks em latência e PSNR.
- Os resultados com ViT-B/16 mostram que o trade-off proposto tem relevância prática.

Não há uma seção explícita de future works no artigo.

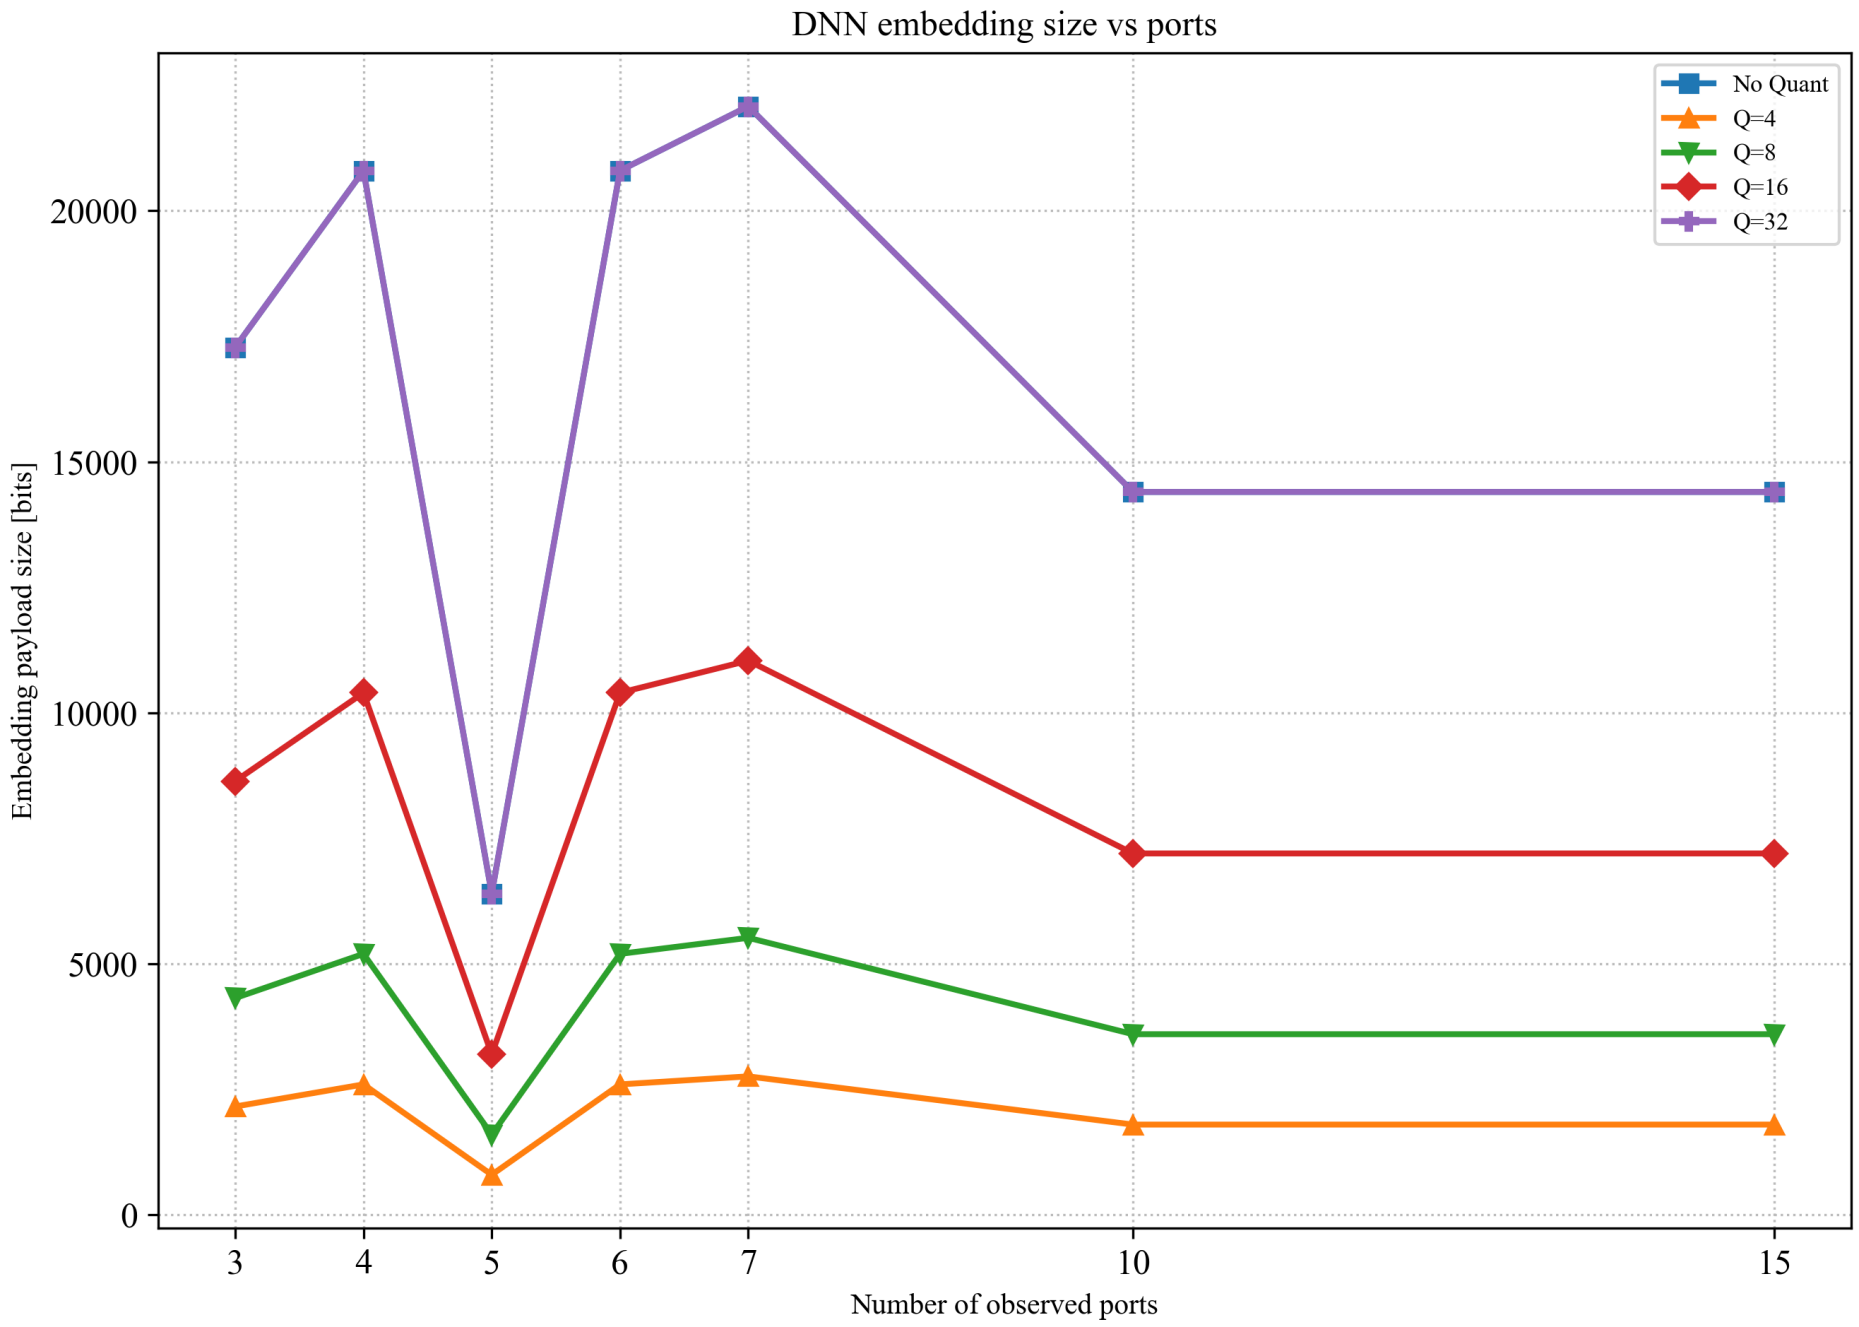
DNN embedding size vs ports
No Quant
Q=4
Q=8
Q=16
Q=32
Embedding payload size [bits]
0
5000
10000
15000
20000
3
4
5
6
7
10
15
Number of observed ports

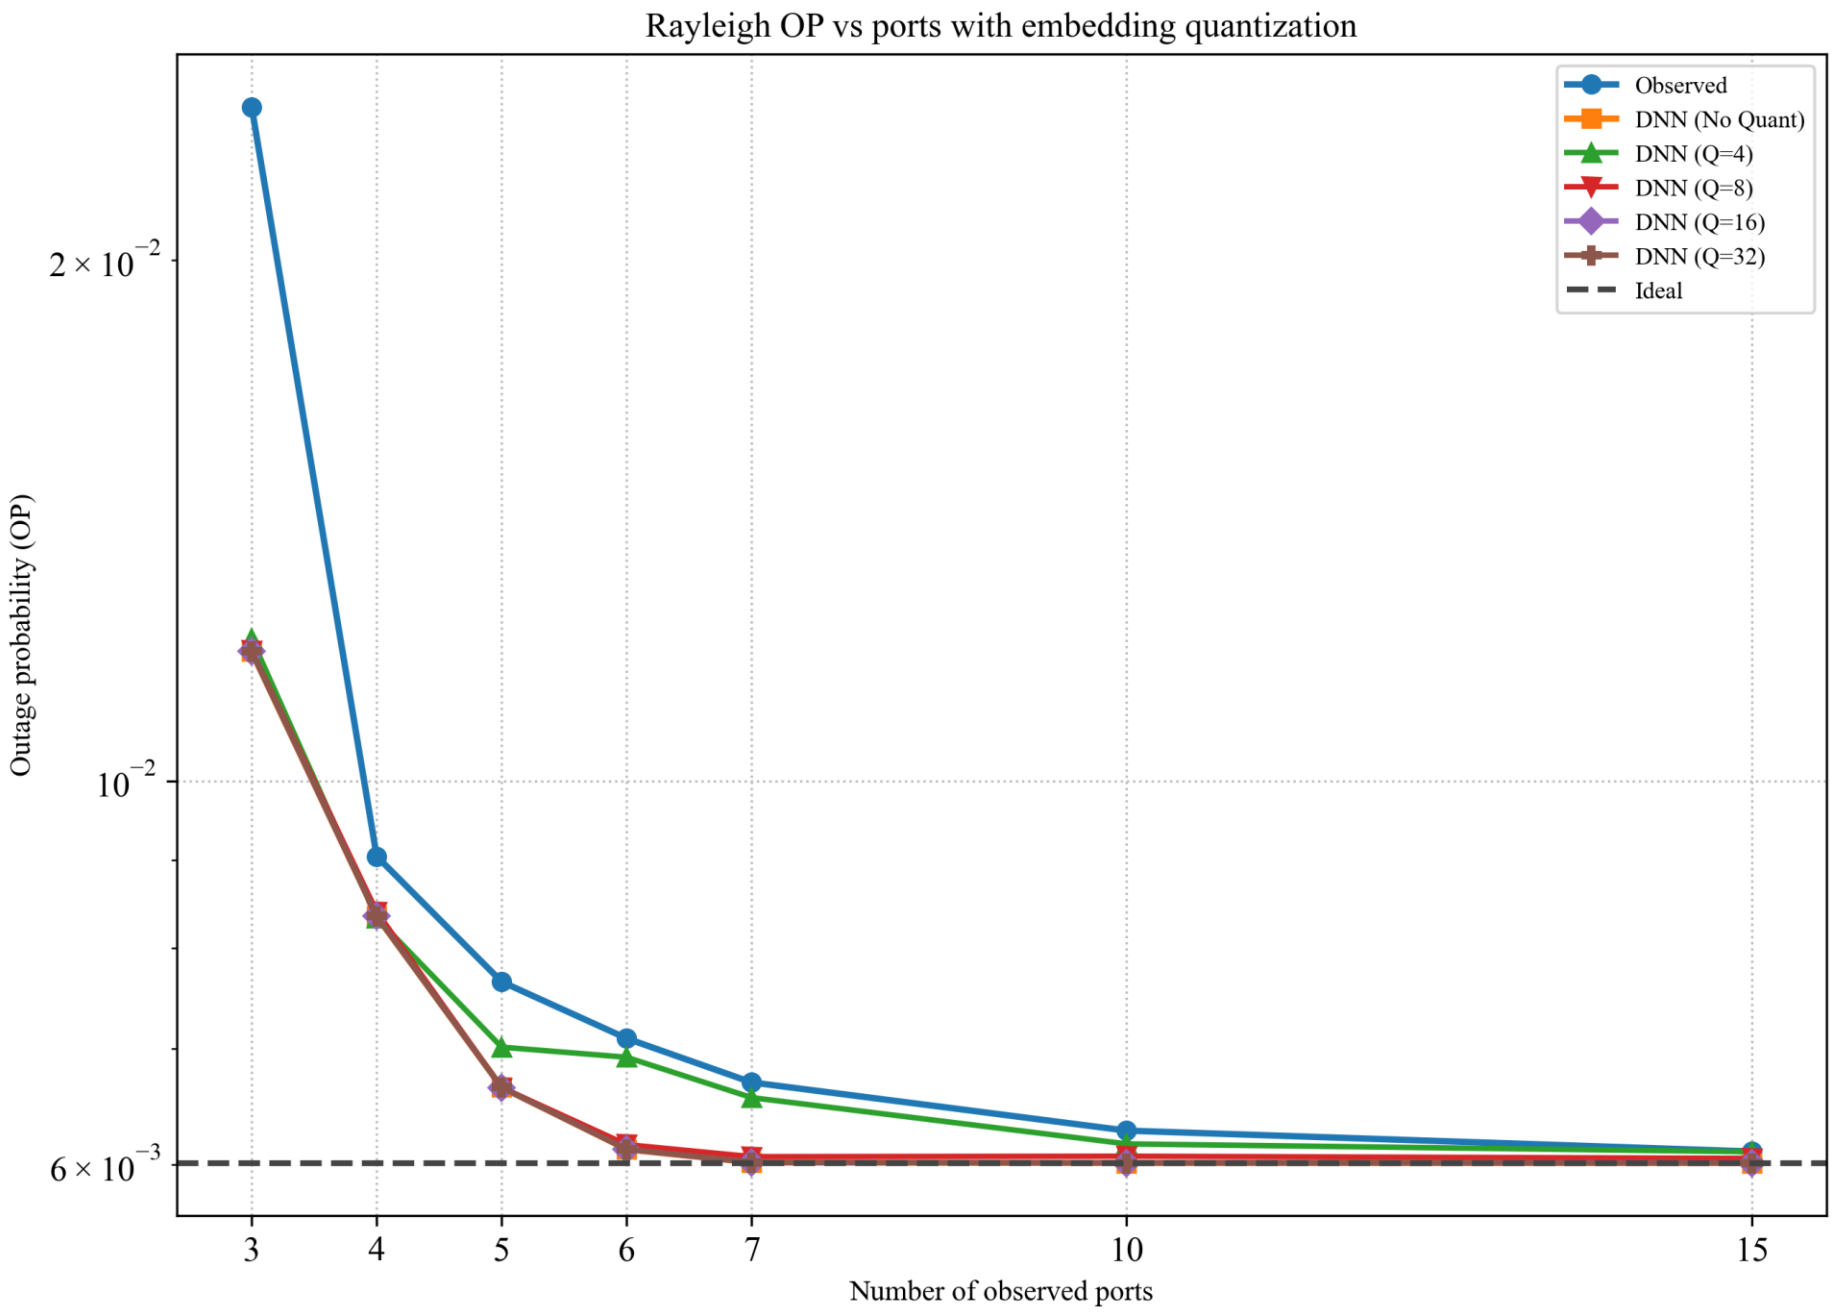
Rayleigh OP vs ports with embedding quantization
Observed
DNN (No Quant)
DNN (Q=4)
DNN (Q=8)
DNN (Q=16)
DNN (Q=32)
Ideal
Outage probability (OP)
2×10^{-2}
10^{-2}
6×10^{-3}
3
4
5
6
7
10
15
Number of observed ports

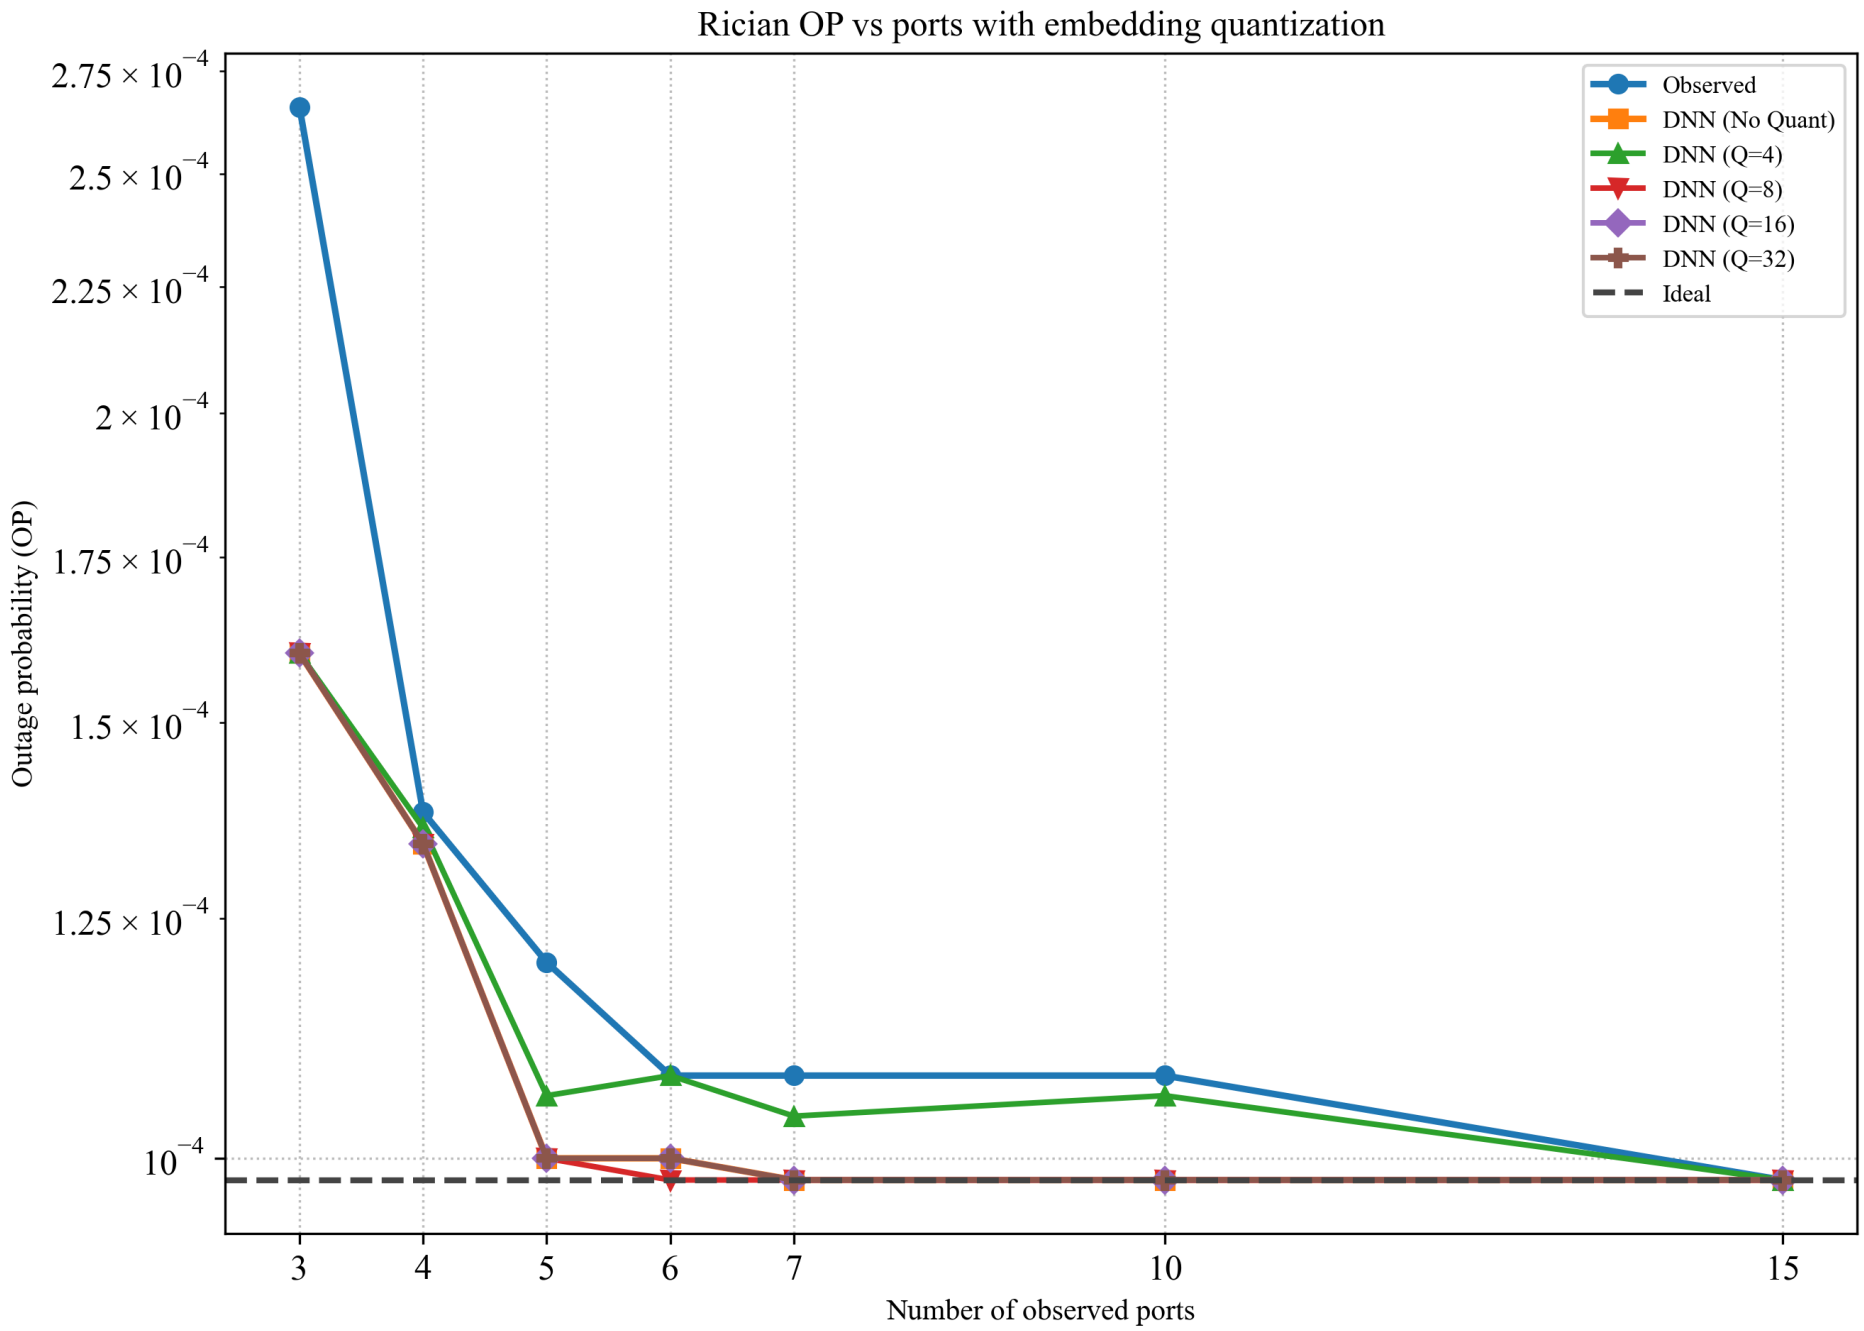
Rician OP vs ports with embedding quantization
Observed
DNN (No Quant)
DNN (Q=4)
DNN (Q=8)
DNN (Q=16)
DNN (Q=32)
Ideal
Outage probability (OP)
2.75×10^{-4}
2.5×10^{-4}
2.25×10^{-4}
2×10^{-4}
1.75×10^{-4}
1.5×10^{-4}
1.25×10^{-4}
10^{-4}
3
4
5
6
7
10
15
Number of observed ports

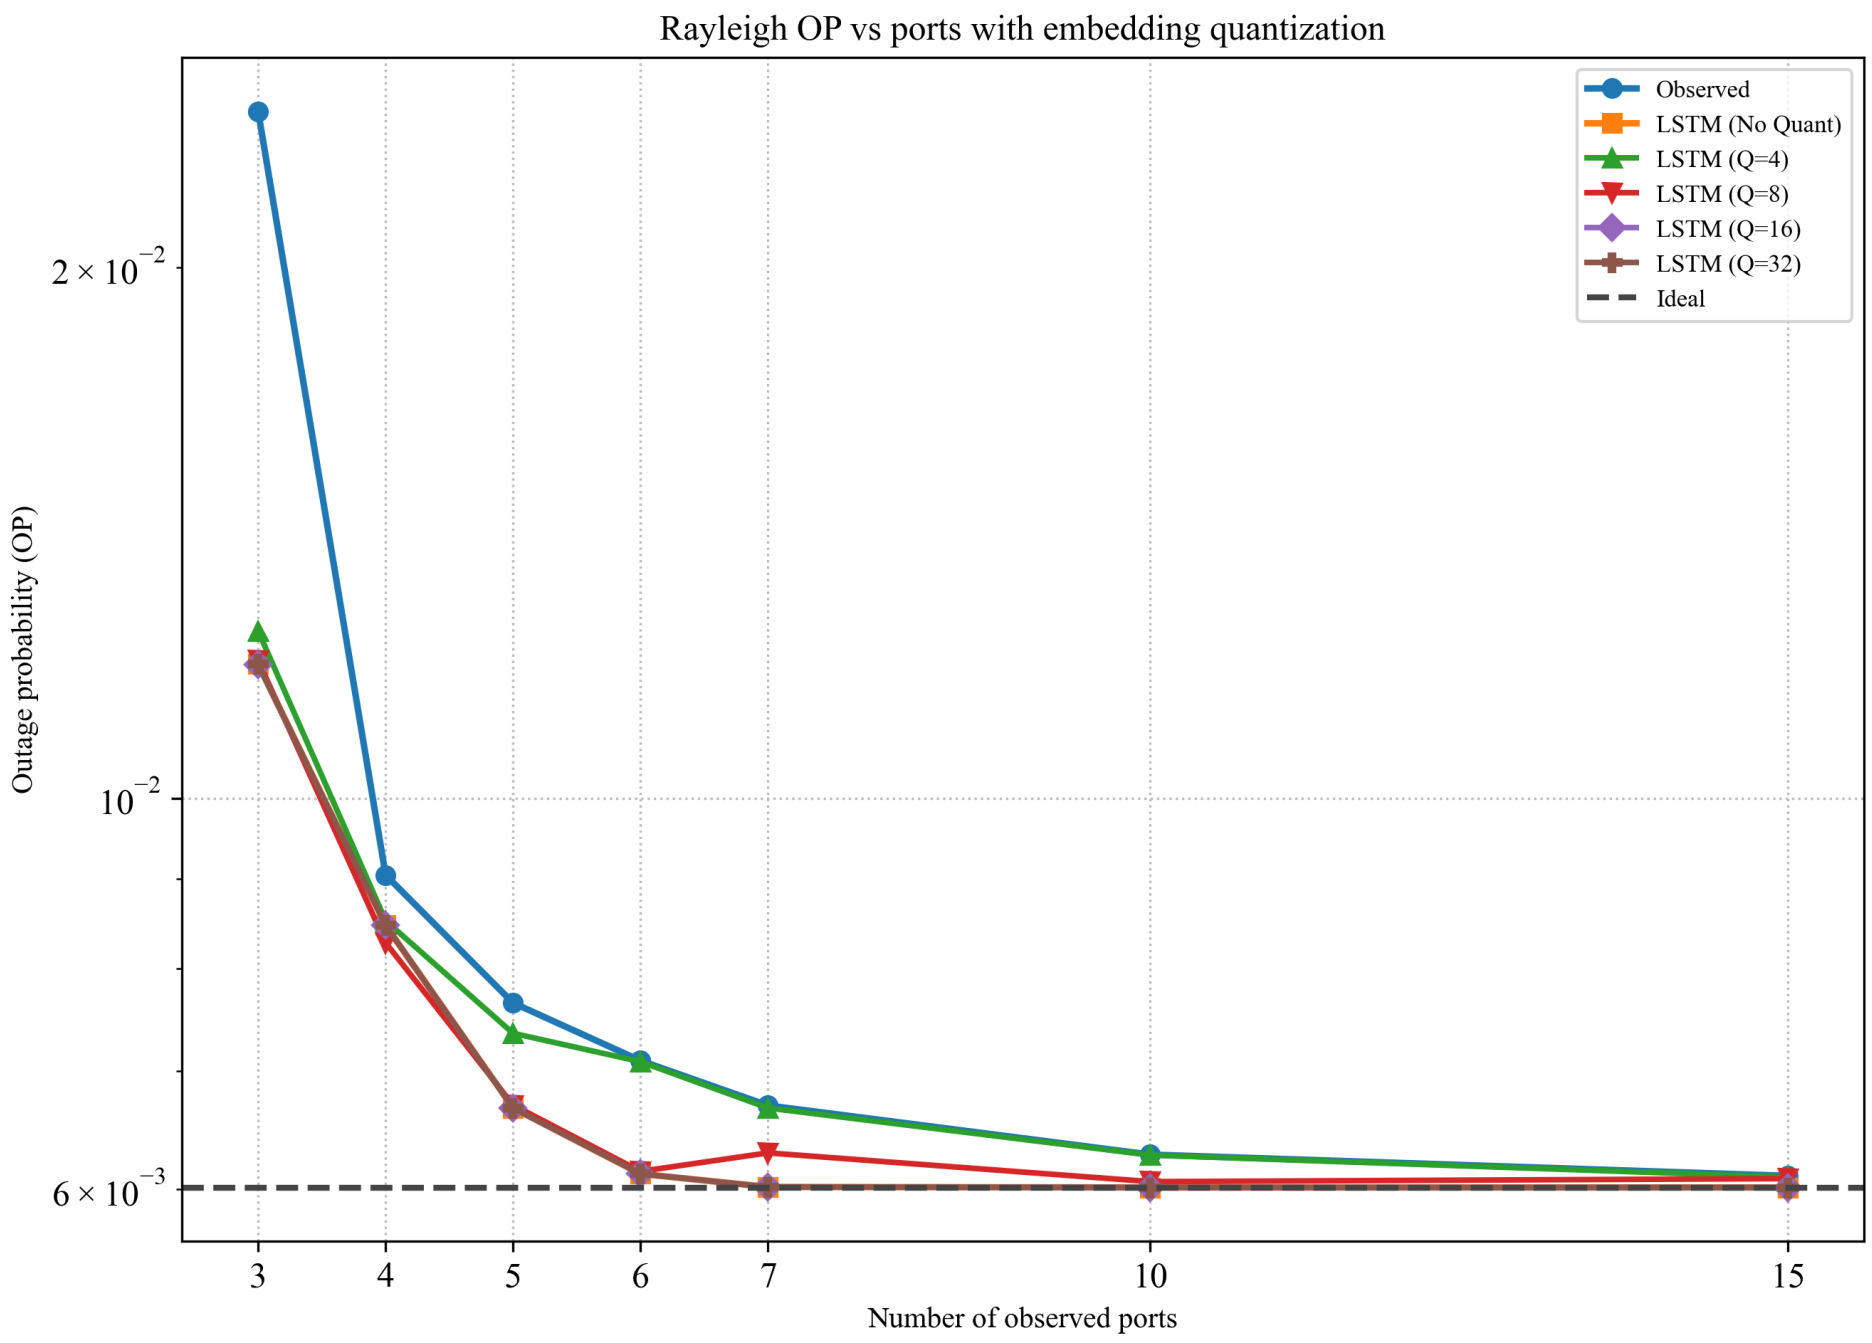
Rayleigh OP vs ports with embedding quantization
Observed
LSTM (No Quant)
LSTM (Q=4)
LSTM (Q=8)
LSTM (Q=16)
LSTM (Q=32)
Ideal
Outage probability (OP)
2×10^{-2}
10^{-2}
6×10^{-3}
3
4
5
6
7
10
15
Number of observed ports

Perguntas?

Quiz

https://forms.gle/zrBqEq5NkGyfk38n8

"Os autores explicitam $O(U)$ para $P1$ e $P2$. Para $P3$, eles remetem ao RADMM, cuja referência fornece complexidade iterativa $O(1/\varepsilon^4)$ para atingir um ponto ε-estacionário. Já para $P4$, eles remetem ao paper de movable antennas, mas essa referência não traz de forma direta uma expressão geral simples para o mesmo subproblema, apenas fórmulas para casos especiais como MISO e SIMO."

mas, nas partes encontradas, a fórmula explícita de complexidade que apareceu foi esta, para o **caso SIMO**, aplicando o algoritmo do caso MISO:

$$O\big(\big(L_r\gamma_r^1 + M^{2.5}\ln(1/\beta)\gamma_r^2 + ML_t + L_t\gamma_t^1\big)\gamma\big)$$

E, para o **caso MISO**, apareceu uma expressão análoga:

$$O\big(\big(NL_r + L_r\gamma_r^1 + L_t\gamma_t^1 + N^{2.5}\ln(1/\beta)\gamma_t^2\big)\gamma\big)$$

Referências

- [1] Y. Jin, Z. Li, Z. Ren, Q. Lin, and Y.-C. Wu, “Balancing Latency and Model Accuracy for Fluid Antenna-Assisted LM-Embedded MIMO Network,” *arXiv preprint* arXiv:2508.01689, 2025.
- [2] Z. Lin, G. Qu, Q. Chen, X. Chen, Z. Chen, and K. Huang, “Pushing large language models to the 6G edge: Vision, challenges, and opportunities,” *arXiv preprint* arXiv:2309.16739, 2024.
- [3] A. Gholami, S. Kim, Z. Dong, Z. Yao, M. W. Mahoney, and K. Keutzer, “A survey of quantization methods for efficient neural network inference,” *arXiv preprint* arXiv:2103.13630, 2021.
- [4] K.-K. Wong, A. Shojaeifard, K.-F. Tong, and Y. Zhang, “Fluid antenna systems,” *IEEE Transactions on Wireless Communications*, vol. 20, no. 3, pp. 1950–1962, Mar. 2021.
- [5] W. Ma, L. Zhu, and R. Zhang, “MIMO capacity characterization for movable antenna systems,” *IEEE Transactions on Wireless Communications*, vol. 23, no. 4, pp. 3392–3407, Apr. 2024.
- [6] Y. Zhao, M. Xu, P. Wang, and D. Niyato, “Fluid antenna enabled Over-the-Air federated learning: Joint optimization of positioning, beamforming, and user selection,” *arXiv preprint* arXiv:2503.00011, 2025.
- [7] M. Ahmadzadeh, S. Pakravan, G. A. Hodtani, M. Zeng, J.-Y. Chouinard, and L. A. Rusch, “Enhanced Over-the-Air federated learning using AI-based fluid antenna system,” *arXiv preprint* arXiv:2407.03481, 2025.
- [8] J. Li, S. Ma, and T. Srivastava, “A Riemannian ADMM,” *arXiv preprint* arXiv:2211.02163, 2024.
- [9] X. Chen, B. Feng, Y. Wu, D. W. Kwan Ng, and R. Schober, “Joint beamforming and antenna movement design for moveable antenna systems based on statistical CSI,” in *2023 IEEE Global Communications Conference (GLOBECOM)*, Dec. 2023.

Referências

•[10] R. Krishnamoorthi, “Quantizing deep convolutional networks for efficient inference: A whitepaper,” *arXiv preprint* arXiv:1806.08342, 2018.
•[11] L. Qian and J. Zhao, “User association and resource allocation in large language model based mobile edge computing system over 6G wireless communications,” *arXiv preprint* arXiv:2310.17872, 2024.
•[12] W.-B. Kou, G. Zhu, R. Ye, Q. Lin, Z. Ren, M. Tang, and Y.-C. Wu, “Adverse weather-immune semantic segmentation with unfolded regularization and foundation model knowledge distillation for autonomous driving,” *arXiv preprint* arXiv:2409.14737, 2024.
•[13] D. Zhen, Y. Zhewei, G. Amir, M. Michael, and K. Kurt, “HAWQ: Hessian aware quantization of neural networks with mixed-precision,” *arXiv preprint* arXiv:1905.03696, 2018.
•[14] C. Guo, L. Zhao, Y. Cui, Z. Liu, and D. W. K. Ng, “Power-efficient wireless streaming of multi-quality tiled 360 VR video in MIMO-OFDMA systems,” *IEEE Transactions on Wireless Communications*, vol. 20, no. 8, pp. 5408–5422, Aug. 2021.
•[15] X. Yu, J.-C. Shen, J. Zhang, and K. B. Letaief, “Alternating minimization algorithms for hybrid precoding in millimeter wave MIMO systems,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 10, no. 3, pp. 485–500, Apr. 2016.
•[16] G. Hu, Q. Wu, K. Xu, J. Si, and N. Al-Dhahir, “Secure wireless communication via movable-antenna array,” *IEEE Signal Processing Letters*, vol. 31, pp. 516–520, Jan. 2024.
•[17] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” *arXiv preprint* arXiv:2010.11929, 2021.

Obrigado!